

低数据强化学习中的数学推理行为校准： 1-shot GRPO 的受控实验与机制分析

Behavioral Calibration for Mathematical Reasoning under
Low-Data Reinforcement Learning: Controlled Experiments and
Mechanistic Evidence for 1-shot GRPO

作者 Xu, Zihang

单位 CUHK(ShenZhen)

课程/项目 MDS5910 Capstone Project

日期 2026 年 4 月 12 日

摘要

本文研究极低数据强化学习场景下 1-shot GRPO 对数学推理模型的作用机制。近期关于 1-shot RLVR 的研究表明，即使只使用一个带可验证奖励的训练样本，强化学习仍可能显著提升数学推理表现 [1]。在这一发现的基础上，本文比较 Qwen2.5-Math-1.5B 与 Qwen2.5-Math-1.5B-Instruct 上的五组结果设置，并结合验证正确率、响应长度、置信度、熵和停止行为等诊断指标分析训练后的生成分布变化。

结果呈现出清晰的模型家族差异：Base 模型在有意义奖励监督下获得约 0.20 的验证分数提升，而 Instruct 模型由于起点更高，只表现出小幅局部变化。将训练 group size 从 $n=8$ 降到 $n=1$ 会削弱但不会消除收益；采用随机错误奖励时，Base 模型不再复现正常奖励条件下的提升，而是在分数与行为指标上同步坍塌。除主分数外，Base 模型在正常奖励条件下还同时表现出响应长度缩短、答案尾部置信度上升、低置信 token 比例下降、token entropy 下降以及 EOS 结束概率上升等一致变化。

这些结果支持一个直接解释：在当前设置下，1-shot GRPO 对 Base 数学推理模型的主要作用是快速行为校准，而不是注入额外数学知识。本文的贡献在于提供了 group size 与奖励有效性的同口径比较、围绕分布稳定化的多指标证据链，以及用于定位低数据收益的全量数据经验上界参考。

关键词：低数据强化学习；数学推理；行为校准；GRPO；奖励破坏；token 级诊断

English Abstract

This paper studies 1-shot GRPO for mathematical reasoning under an extremely low-data reinforcement-learning regime. Motivated by recent evidence that verifiable reward can remain effective with a single training example [1], it asks what kind of generation behavior changes when the data budget is so small. The analysis compares five result settings across Base and Instruct model families and combines validation accuracy with diagnostics for length, confidence, entropy, and stopping behavior.

The main finding is a strong asymmetry across model families. The Base model gains roughly 0.20 validation score under meaningful reward supervision, while the Instruct model moves only slightly from an already strong starting point. Reducing the training group size from $n=8$ to $n=1$ weakens but does not remove the gain, and reward corruption causes the Base model to collapse rather than reproduce the meaningful-reward improvement. Across the successful Base settings, training also shortens outputs, lowers entropy, reduces low-confidence token mass, raises tail confidence, and makes stopping behavior sharper. These results support interpreting 1-shot GRPO primarily as fast behavioral calibration for the Base math model.

Keywords: low-data reinforcement learning; mathematical reasoning; behavioral calibration; GRPO; reward corruption; token-level diagnostics

目录

1	引言	1
2	方法背景与研究问题	2
2.1	GRPO 的基本思想	2
2.2	最终正确率之外的诊断指标	2
2.3	研究维度与核心假设	2
3	研究设置	3
3.1	模型、数据与总体流程	3
3.2	主结果设置	3
3.3	训练与评估口径	4
3.4	全量数据经验上界参考	4
4	主结果：1-shot GRPO 的有效性	5
4.1	总体趋势：Base 收益显著，Instruct 收益有限	5
4.2	Base 模型：收益大且具有一致性	7
4.3	Instruct 模型：高起点与小增益	8
4.4	最佳检查点与最终检查点的偏离	8
5	行为证据：宏观指标与 token 级证据	9
5.1	Base 模型的收缩与稳定化	9
5.2	动态统计进一步强化了上述判断	12
5.3	弱约束版本的启示	15
5.4	Instruct 模型主要是局部微调	15
5.5	Token 级补充证据	16
5.5.1	补充材料的口径与边界	16
5.5.2	直接观察：Base 变化大，Instruct 变化小	16
5.5.3	与主结果结论的衔接	18
5.5.4	前缀分布的重新组织	18
5.5.5	从初始到终点的局部 token 分布收缩	19
5.5.6	按正确性分组的分布分离	19
6	小组规模与奖励信号分析	20

6.1	n=1 小组规模消融的解释边界	20
6.2	随机错误奖励设置的解释意义	21
7	训练动态与证据综合	21
7.1	收益的阶段分布	21
7.2	最佳 checkpoint 与最终 checkpoint 的偏离	22
7.3	终点行为排序的补充证据	23
7.4	多指标之间的耦合关系	24
7.4.1	收益提升与校准量的同步关系	24
7.4.2	终点性能与终点稳定性的共同前沿	25
7.4.3	跨指标图的证据作用	26
8	讨论	27
8.1	主要支持证据	27
8.2	当前限制	27
8.3	外推边界	27
8.4	当前证据链汇总	27
9	结论	28
A	附录：补充讨论	29

1 引言

近年来，大语言模型在数学推理、代码生成和科学问答等复杂推理任务上取得了快速进展 [3, 4, 6, 8, 9]。与纯监督微调不同，带可验证奖励的强化学习能够利用最终答案正确性或过程质量信号，在生成阶段直接优化模型的行为分布 [3, 7, 1]。对于数学推理这类任务而言，模型不仅需要“知道”相关知识，还需要在解题过程中做出一系列结构化决策：是否继续展开、是否及时纠偏、何时终止生成，以及如何在多个候选思路之间重新分配概率质量。这些问题共同决定了最终正确率的上限，也使得基于强化学习的推理优化成为近年研究中的重要方向。

Wang 等人关于 1-shot RLVR 的近期工作进一步把这一问题推向了极低数据场景 [1]。该工作表明，对于 Qwen2.5-Math-1.5B 这样的数学模型，使用单个经过选择的训练样本也可以在 MATH500 以及多个数学推理基准上带来显著提升，并且在某些设置下接近使用更大 RLVR 数据子集得到的效果。更重要的是，该工作同时讨论了 outcome reward 与 format reward 的区别、policy-gradient loss 的主要作用、探索项的重要性，以及训练样本准确率饱和后测试性能仍可继续提升的 post-saturation generalization 现象。这些发现说明，1-shot RLVR 并非孤立的经验现象，而是一个值得进一步开展机制分析的研究场景。

本文沿着上述问题继续展开，但重点从“单样本 RLVR 是否存在显著基准收益”转向“这种收益对应怎样的行为变化”。在当前实践中，GRPO 提供了一种尤其适合推理模型的优化思路。它并不依赖于高精度 critic，而是通过同一输入下多个采样响应之间的相对比较构造训练信号。对于数学题而言，这种组内比较非常自然：同一道题通常可以采样出完全正确、部分正确和明显错误的多条解法，组内差异恰好为训练提供了可利用的排序信号。因此，GRPO 不仅是一种可行的优化方法，也使 group size 本身成为可以被直接检验的机制变量。

在极低数据预算下，GRPO 对模型行为的影响需要更细的受控比较来刻画。本文关注三个问题：1-shot GRPO 是否主要改变已有推理行为而不只是提高分数；这种变化在 Base 与 Instruct 先验之间是否不同；以及它是否依赖 group-relative signal 和有效奖励信号。由此，本文引入 token-level diagnostics、相同验证口径的 $n=1$ 设置和随机错误奖励设置，用于把低数据 RLVR 从单纯分数比较推进到行为机制分析。

围绕这些问题，本文的主要贡献可以概括为三点。第一，本文在 1-shot RLVR 研究脉络下，统一比较五组关键结果设置，并将 $n=1$ 小组规模设置与随机错误奖励设置纳入同一分析框架。第二，本文不仅比较最终 score，还系统整理了多种行为指标与训练过程中的动态统计，从而给出“训练如何改写推理分布”的直接证据。第三，本文进一步引入全量数据训练结果作为经验上界，用于评估 1-shot 收益距离更大数据预算下可达到效果还有多远。后文将依次给出方法背景、研究设置、主结果、行为证据、token 级证据与训练动态综合。

2 方法背景与研究问题

2.1 GRPO 的基本思想

GRPO 的核心在于组内相对比较。对于同一条输入，训练阶段会采样多个候选响应，并依据它们的相对表现形成优势信号。相比传统 PPO 强依赖的状态价值估计，这种做法减少了显式 critic 的复杂度，也更贴近推理任务中的真实训练需求。对于数学推理而言，多个采样结果之间常常体现出清晰的质量差异，例如某些响应中途走偏、某些响应拖尾过长、某些响应则能在较短链路内稳定闭合答案。GRPO 正是利用这些组内差异重新分配概率质量，让下一轮采样更偏向“结构更好”的解法。

在本文整理的主结果中，标准配置采用 `rollout_n=8`。这意味着每个输入在训练阶段会被采样 8 次，以形成组内比较信号。与之对应，Base `n=1` 设置仅把训练阶段的 `rollout_n` 降为 1，同时保持 `val_rollout_n=8` 与 Base `n=8` 一致，用来更直接地测试组内相对信号在当前任务中的作用。由于其他超参数大体保持一致，这种设计使得 group size 成为更直接的主要变量。

2.2 最终正确率之外的诊断指标

仅比较最终 score 会得到过于粗略的结论：Base 模型收益显著，而 Instruct 模型收益有限。然而，这一结论无法解释训练对生成行为的具体影响。为此，本文引入了多种验证期行为指标，包括平均响应长度、答案尾部置信度、低置信 token 比例、token 熵、最终 EOS 概率和平均 top-1 token 概率。它们分别对应模型行为的不同侧面：更短的响应可能意味着推理链更加收敛；更低的 entropy 和更高的 top-1 概率意味着分布更集中；更高的 EOS 概率则表明模型更擅长在恰当位置结束生成。

这些指标能够把“性能提升”拆解成“行为变化”。本文将“行为校准”操作性定义为：在验证正确率提升的同时，模型生成分布朝更短响应、更低 token entropy、更少低置信 token、更高尾部与 top-1 置信度，以及更清晰 EOS 结束行为的方向同步移动。这个定义描述的是可观测的分布变化，并不等同于声称模型学习了新的数学事实。

2.3 研究维度与核心假设

本文围绕以下五个研究维度展开：

- 1-shot GRPO 在数学推理任务上带来的可重复性能提升。
- Base 模型与 Instruct 模型之间的收益规模差异。
- 训练收益与 entropy、低置信 token 比例和 EOS 结束行为之间的系统关联。
- 受扰动训练信号对正常奖励收益的削弱程度。
- 将 group size 从 8 降到 1 后，组内相对信号减弱对训练改进的影响。

对应地，本文采用如下假设作为分析线索：第一，1-shot GRPO 更符合快速校准机制，而不是能力注入机制；第二，先验更弱的 Base 模型收益空间更大；第三，行为层指标会与主分数共同变化；第四，随机错误奖励设置不应复现正常奖励条件下的收益；第五，若 group-relative signal 很关键，则 $n=1$ 应表现出明显衰减。后文的结果分析将围绕这些假设逐条展开。

3 研究设置

3.1 模型、数据与总体流程

本文涉及两类模型：Qwen2.5-Math-1.5B 与 Qwen2.5-Math-1.5B-Instruct。验证集统一采用 MATH500，训练模式统一为 one-shot 设定。虽然这里的 one-shot 并不意味着只有单条样本，而是指训练数据规模被压缩到极低预算，但这一设置与本文关注的低数据强化学习机制问题相匹配。

从设置配置可以看出，各条件在学习率、batch size、`test_freq` 和总 epoch 数上具有较高一致性，主要变化集中在三类因素上：模型先验（Base 或 Instruct）、正则化强度（标准或弱正则化）以及 group size ($n=8$ 或 $n=1$)。这意味着不同设置之间具备较好的对照价值。

3.2 主结果设置

表 1 汇总了五组关键设置的核心结果。本文采用如下结果标签：Base $n=8$ 、Base $n=1$ 、Base weak-reg.、Base random-reward 与 Instruct $n=8$ 。此外，附录还保留一组全量数据与格式约束参考结果，用于补强对奖励结构和数据规模的讨论，但不与正文主结果混合比较。

表 1: 五组关键设置的主结果汇总

设置	初始	final	增量	最佳检查点	best score
Base $n=8$	0.3745	0.5733	+0.1988	156	0.5753
Base $n=1^a$	0.3630	0.5470	+0.1840	174	0.5590
Base weak-reg.	0.3745	0.5747	+0.2002	174	0.5765
Base random-reward ^b	0.3630	0.0003	-0.3628	0	0.3630
Instruct $n=8$	0.6837	0.6873	+0.0035	162	0.6995

^a Base $n=1$ 采用与 Base $n=8$ 相同的 `val_rollout_n=8` 设置，因此每个验证检查点同样约 4000 条记录，可直接进行同口径比较。

^b Base random-reward 采用随机错误奖励构造，定位为奖励破坏设置，而不是无奖励设置。

3.3 训练与评估口径

本文比较的五组设置都覆盖 step 0 到 step 180，步长为 6。每个检查点的结果均由逐样本验证记录聚合得到。五组设置都采用约 4000 条验证记录，因此主分数曲线、最佳检查点和检查点级波动具备较好的可比性。尤其是 Base n=8、Base n=1 以及 Base random-reward，共享同一验证采样口径。

另一个需要记录的口径是 token diagnostics 的覆盖范围。结合逐样本验证记录的保存结果，更准确的描述是：每个检查点最多有 64 个样本参与 token-level diagnostics 统计，但只有其中 8 条样本会额外保存完整的 token_diagnostics 轨迹。对于主 n=8 设置，这 8 条完整轨迹通常对应同一固定题目的 8 次采样，因此 token 级分析更适合作为机制证据，而不适合作为“全任务统计结论”。动态统计进一步表明，五组设置在每个验证检查点上都稳定分析 64 个样本，覆盖率约为 1.6%。

3.4 全量数据经验上界参考

除主结果表外，本文还系统整理了一组全量数据与格式约束参考结果。这批结果不直接并入表 1，原因在于训练文件范围与记录覆盖并不完全一致；但它们对全文论证仍然很重要，因为它们为低数据设置提供了一个经验上界。具体而言，Base 家族中，full 训练由 0.3630 提升到 0.6053，显著强于 1-shot 的 0.5753；Instruct 家族中，full 也高于 1-shot，但绝对差值仅约 0.0143。与此同时，Base 家族的格式约束主导参考仅从 0.3630 提升到 0.4490，明显弱于常规奖励路径。

这里的 full 沿用 1-shot RLVR 原文的数据口径，指从 DeepScaleR-Preview-Dataset 随机抽取的 1209 条 DSR-sub instance pool；1-shot 指同一 DSR-sub 中被选出的单个样本 π_1 [1, 2]。

这批参考结果之所以值得写入正文，并不是因为它们能替代表 1 的同口径比较，而是因为它们提供了一个可解释的经验上界参照。第一，它们说明“Base 家族收益显著、Instruct 家族收益有限”并不依赖于单一结果表。第二，它们说明“1-shot 有效，但通常弱于全量数据训练”。第三，格式约束主导参考的明显劣势进一步支持了本文关于“奖励结构本身会影响最终上限”的论断。换言之，主结果表负责回答“在同口径下结论是否成立”，而全量数据参考负责回答“低数据收益距离更大数据预算下的经验上界还有多远”。

表 2: 全量数据结果作为 1-shot 训练的经验上界参考

模型家族	1-shot final	full final	final 差距	best 差距
Base	0.5753	0.6053	+0.0300	+0.0333
Instruct	0.6928	0.7070	+0.0143	+0.0085

注：差距定义为全量数据结果减去对应的 1-shot 结果。该表用于提供经验上界，不作为表 1 的同口径比较项。




图 1: 全量数据与格式约束参考结果的初始值、终点值与最佳值对比。该图表明，无论在 Base 还是 Instruct 家族中，full 训练通常都优于 1-shot；同时，Base 家族中的格式约束主导参考明显弱于常规奖励路径。

表 2 和图 1 因而承担了正文里的一个特殊角色：它们不是主结论的直接来源，而是对主结论进行上界定位和外部参照补强。这类材料的价值在于，它可以避免全文叙事完全建立在单一结果表之上，使“Base 更敏感于训练范式和奖励结构、Instruct 整体收益更温和”这一判断具有更宽的经验基础。

4 主结果：1-shot GRPO 的有效性

4.1 总体趋势：Base 收益显著，Instruct 收益有限

表 1 呈现出两个主要现象。第一，Base 模型在多个设置中都表现出接近 0.20 的绝对分数提升，说明 1-shot GRPO 在弱先验数学模型上能够产生稳定而显著的收益。第二，Instruct 模型的改进明显更小，其结果更接近高性能附近的局部微调，而不是结构性变化。这与方法部分提出的先验差异假设高度一致。




图 2: 五组设置的 validation score 随训练检查点的变化。Base 正常奖励设置整体抬升明显，而随机错误奖励设置则快速坍缩。

图 2 强化了表格中的结论。Base 系列从较低起点快速上升，并在中后期进入相对平稳的高位区间；Instruct 系列则从一开始就处于较高水平，后续训练带来的变化幅度明显更小。这意味着不能用同一个收益尺度评价两类模型。对于 Base 模型，训练是在帮助它脱离“高熵、长拖尾、低置信”的初始状态；而对于 Instruct 模型，训练更接近对已有分布进行局部调整。




图 3: Base、Instruct 与随机错误奖励设置的 validation score 局部视图。

由于五组设置的分数量级差异较大，单独依赖图 2 容易压缩局部差异。图 3 因而承担一个补充角色：左图把三个成功的 Base 条件放在相近尺度上，能够更清楚地看到 Base weak-reg. 与 Base n=8 非常接近，而 Base n=1 则稳定偏低；中图则表明 Instruct 模型虽然总增益很小，但在高位区间内仍存在可辨别的局部波动；右图把随机错误奖励条件下的坍缩单独展开，从而避免它在总览图里仅仅表现为“贴近零值的一条线”。

4.2 Base 模型：收益大且具有一致性

Base $n=8$ 从 0.3745 提升到 0.5733，说明标准设定下的 1-shot GRPO 已经足以将基础数学模型从较不稳定的初始状态提升到更高性能区间。更值得注意的是，这一收益并不是孤例。Base weak-reg. 的 final score 为 0.5747，与标准设置非常接近；而 Base random-reward 却从 0.3630 快速坍缩到 0.00025。二者构成一组更具解释力的对照：当奖励结构保持有效时，Base 模型的收益具有较强一致性；而当奖励信号被系统性破坏后，这种收益不会出现。




图 4: Base 家族四组设置的主分数变化。三个正常奖励方向设置表现出前中期快速上升，而随机错误奖励设置则快速失稳。




图 5: Instruct 家族 $n=8$ 设置的主分数变化。曲线整体维持在高位，训练主要表现为小幅波动与局部微调。

图 4 与图 5 进一步说明，Base 家族的多个设置虽然有不同后期波动，但都共享一种相似的学习形态：前中期快速上升，后期进入缓慢振荡；Instruct 家族则主要维持在高位窄幅波动。这提示在极低数据预算下，最佳 checkpoint 未必总是最终 checkpoint；在结果分析中区分二者是有意义的。

4.3 Instruct 模型：高起点与小增益

Instruct $n=8$ 在 step 0 就达到 0.6837，这一数值远高于 Base 模型的起点。训练后的 final score 为 0.6873，最佳检查点为 162，best score 为 0.6995。若只看数值，它仍然是一个有效设置，但其收益量级只有 0.0035，与 Base 模型约 0.20 的绝对提升完全不在同一量级。

因此，更准确的叙事不是“1-shot GRPO 对所有模型都同样有效”，而是“1-shot GRPO 的收益高度依赖于模型起点”。对于高先验 Instruct 模型，训练已经很难带来显著的结构收益；对于先验较弱的 Base 模型，训练空间则大得多。

4.4 最佳检查点与最终检查点的偏离

另一个不可忽略的观察是，多个设置的最佳分数并不出现在最终 step 180。例如，Base $n=8$ 的最好结果出现在 step 156，Base weak-reg. 出现在 step 174，Instruct $n=8$ 的最佳检查点则是 162。这一现象说明在当前训练预算下，模型的收益并不是单调累积的；相反，训练中后期可能进入高位波动区间。因此，在结果分析中区分“最终 checkpoint”和“最佳 checkpoint”是必要的。

5 行为证据：宏观指标与 token 级证据

5.1 Base 模型的收缩与稳定化

仅比较 score 可以确认 Base 模型收益，但不足以解释收益的行为来源。行为指标提供了更直接的机制证据。表 3 显示，Base n=8 在最终阶段的平均 response length 为 603.1，相比起点明显缩短；答案尾部置信度提升到 0.9331；低置信 token 比例降到 0.0325；token entropy 降到 0.1839；最终 EOS 概率上升到 0.9880。这组变化表明，模型较少表现为冗长试探，并更快趋于稳定闭合。

表 3: 五组设置的最终行为指标汇总

设置	长度	尾部置信	低置信	熵	EOS	top-1
Base n=8	603.1	0.9331	0.0325	0.1839	0.9880	0.9354
Base n=1	580.4	0.9003	0.0488	0.2811	0.9215	0.9227
Base weak-reg.	578.6	0.9437	0.0294	0.1563	0.9738	0.9437
Base random-reward	1192.4	0.0001	1.0000	11.5466	0.0009	0.0021
Instruct n=8	470.3	0.9571	0.0187	0.1322	0.9926	0.9634

注：短标签对应表 1 中的五组设置；EOS 指最终 EOS 概率，top-1 指平均 top-1 token 概率。

这类变化与“能力注入”并不完全一致，却与“快速校准”高度吻合。短期知识学习并不必然导致长度缩短、结束概率上升和熵下降同时出现；相反，如果模型学会更稳定地组织原有解题习惯，这些指标更可能同步变化。因此，训练收益更适合被解释为对分布进行重新整形，而不是为模型引入额外知识模块。




图 6: Base 家族四组设置的验证响应长度变化，包含全尺度视图与局部放大视图。




图 7: Base 家族四组设置的验证 token entropy 变化, 包含全尺度视图与局部放大视图。




图 8: Base 家族四组设置的低置信 token 比例变化, 包含全尺度视图与局部放大视图。




图 9: Base 家族四组设置的最终 EOS 概率变化, 包含全尺度视图与局部放大视图。




图 10: Base 家族四组设置的答案尾部置信度变化，包含全尺度视图与局部放大视图。




图 11: Base 家族四组设置的平均 top-1 token 概率变化，包含全尺度视图与局部放大视图。

图 6 到图 11 使这种行为变化更加直观。每张图都采用“全尺度视图 + 正常奖励条件局部放大”的设计：全尺度视图保留随机错误奖励设置的异常方向，局部放大视图则避免异常线压缩正常条件之间的差异。尤其值得关注的是 response length、tail confidence、top-1 probability 与 EOS probability 的联动：随着训练进行，Base 家族普遍变得更短，也更倾向于在合适位置结束；与此同时，token entropy 与低置信 token 比例同步下降，而答案尾部置信度与平均 top-1 概率同步上升。这表明模型并非通过延长输出提升分数，而是通过更稳定的结束行为提升分数。对数学题这种最终答案明确、拖尾容易引入错误的任务而言，这一点尤其关键。




图 12: 非坍塌设置的行为细节图。该图聚焦四个非坍塌条件在 token entropy、low-confidence ratio、最终 EOS 概率与 top-1 probability 上的细微差异。

如果把随机错误奖励设置保留在同一坐标尺度里，许多成功条件之间的细节差异会被明显压缩。图 12 因而只保留四个非坍塌条件，用于比较成功设置之间的局部差异。该图显示：Base weak-reg. 在 entropy、top-1 probability 和 EOS probability 上都表现出更强的收缩，而 Base $n=1$ 则在这些指标上持续落后；Instruct $n=8$ 的曲线整体变化较小，更接近低熵高置信区域内的局部调整。

5.2 动态统计进一步强化了上述判断

训练与验证阶段的动态统计把前面的静态结果推进到了过程层面。与只看最终 checkpoint 不同，这些统计同时记录了训练期的 actor/entropy 和验证期的聚合 token 指标，因此能更直接地区分“真正变得更稳定的策略”和“仅在终点分数上略占优势的策略”。表 4 汇总了五组设置从起点到终点的核心变化。

表 4: 训练与验证动态统计摘要 (起点 → 终点)

设置	actor 熵	验证熵	低置信	长度	top-1
Base n=8	0.346→0.116	0.660→0.202	0.115→0.037	812.5→603.1	0.854→0.932
Base n=1	0.641→0.085	0.532→0.317	0.095→0.051	762.8→580.4	0.873→0.921
Base weak-reg.	0.346→0.091	0.660→0.156	0.115→0.030	812.5→578.6	0.854→0.944
Base random-reward	0.376→11.594	0.633→11.547	0.110→1.000	762.8→1192.4	0.856→0.002
Instruct n=8	0.118→0.062	0.111→0.156	0.017→0.022	473.2→470.3	0.964→0.961

注：起点取第一个有值的训练或验证检查点，终点取最终验证检查点。验证 token 指标来自聚合 token diagnostics，每个检查点分析 64 个样本；五组设置的覆盖率均约为 1.6%。




图 13: 五组设置训练期 actor/entropy 变化，包含全尺度视图与局部放大视图。




图 14: 相同评估口径下, Base $n=8$ 与 Base $n=1$ 的六项动态对比。

这张表最直接地展示了 Base 与 Instruct 的分化。以 Base $n=8$ 为例, actor/entropy 从 0.346 降到 0.116, 验证 token entropy 从 0.675 降到 0.184, 低置信 token 比例从 0.116 降到 0.032, 聚合 top-1 概率从 0.851 升到 0.935, 验证响应长度则从 812.5 缩短到 603.1。弱正则化设置的收缩更强: 对应的最终 actor/entropy 进一步降到 0.091, 验证 token entropy 降到 0.156, top-1 概率升到 0.944。与之相对, Base random-reward 并未出现任何“轻微变差但仍有学习”的形态, 而是沿着完全相反的方向发展: actor/entropy 从 0.376 升到 11.594, 验证 token entropy 从 0.633 升到 11.547, 低置信 token 比例升到 1.000, top-1 概率坍缩到 0.002, 验证响应长度则暴涨到 1192.4。也就是说, Base 家族在正常奖励条件下的收益并不只是最终 reward 提高, 而是伴随着训练熵下降、验证熵下降、低置信 token 减少、top-1 概率升高与长度缩短的一整套同步变化; 一旦奖励信号被系统

性破坏，这整套变化会整体反向。

Base $n=1$ 进一步细化了 group size 的作用。该设置在 step 0 为 0.363，最终为 0.547，最佳检查点为 174、best score 为 0.559。在与 Base $n=8$ 完全一致的验证口径下，把训练 group size 从 8 降到 1 后，模型依然获得了显著收益，但 final score 低了约 0.026，best score 也低了约 0.016。与此同时，它的最终 token entropy 为 0.317，明显高于 Base $n=8$ 的 0.202 与 Base weak-reg. 的 0.156；低置信 token 比例为 0.051，也高于对应的 0.037 和 0.030；平均 top-1 概率则只有 0.921，低于 $n=8$ 的 0.932。图 14 进一步表明，这种差异不是单个 final checkpoint 的偶然波动，而是贯穿 score、entropy、length 与 top-1 probability 的整体形态差异。因此，把 group size 降到 1 不会阻止学习，但会削弱分布收缩与稳定闭合的质量。

Instruct 家族则呈现出另一种模式。Instruct $n=8$ 的 actor/entropy 只从 0.118 降到 0.062，验证长度几乎不变，top-1 概率也基本维持在 0.96 附近。这更接近局部调整，而不是结构性重整。在高先验模型上，当前 one-shot 级别的强化学习更多是在已有稳定分布附近进行细节调整，而不是像 Base 家族那样触发一次明显的分布重排。

5.3 弱约束版本的启示

Base weak-reg. 的 final score 与标准设置非常接近，但它的最终 entropy 更低、top-1 概率更高、响应也更短。这说明关闭 KL 和 entropy 约束后，模型并未立即失稳，而是朝着更强的分布收缩方向前进。这里需要谨慎：更强的收缩既可能意味着“更快收敛到较优解法”，也可能意味着“更容易过拟合或更依赖少量样本偏差”。当前证据只能确认它没有显著损伤最终准确率，但不能据此得出“约束项可有可无”的结论。

弱正则化设置的价值不在于证明约束无用，而在于表明：在极低样本强化学习里，最终分数并不足以代表训练过程的健康程度。后续分析可进一步关注检查点级波动和 representative failure case。

5.4 Instruct 模型主要是局部微调

Instruct $n=8$ 的最终行为指标呈现出另一种图景。它的 response length 本来就较短，tail confidence 本来就很高，low-confidence token ratio 也处于较低水平。训练后虽然仍然有一定变化，但幅度远小于 Base 模型。例如，它的 entropy 只是在低位小幅波动，EOS probability 始终接近 0.99。这说明 Instruct 模型的主要变化不是从高不确定性状态走向有序，而是在已有稳定分布上进行细节调整。

这类结果对研究假设具有关键意义。它说明同样的 1-shot GRPO 并不会以同样方式作用于所有模型。对于先验较弱的 Base 模型，它更接近校准机制；对于先验较强的 Instruct 模型，它更接近局部调整机制。

5.5 Token 级补充证据

5.5.1 补充材料的口径与边界

本文还纳入了一份 token 级诊断分析。它并不覆盖全部主结果设置，而是聚焦于固定题目上的完整轨迹子集。结合当前配置，更准确的理解应当是：每个检查点、每个设置最多有 64 个样本参与 token diagnostics 统计，但只有 8 条样本保留完整 token 轨迹，而且每条记录只保留前约 96 个 token。因此，这部分材料更适合作为“机制补充证据”，而不宜被直接外推为“对全部 500 题均成立的统计结论”。

尽管覆盖范围有限，这批 token 轨迹仍然具有较高价值。原因在于，它确实保留了 token 位置级的 `logprob`、`entropy`、`top1_prob` 和 `top-k mass` 等信息，可以更直接地检验“训练是否在早期 token 组织上做了校正”。需要同时指出的是，本文还额外拥有五组设置共享的聚合 token 摘要曲线，因此 token 证据已经分成两层：一层是 64-sample 聚合统计，用于支持整体方向；另一层是固定题目的完整轨迹，用于展示局部机制。

5.5.2 直接观察：Base 变化大，Instruct 变化小

图 15 与图 16 给出了固定题目上的 token 级可视化结果。Instruct 系列在 step 0 就已经具备较高的 token confidence 和较低的 entropy，训练后变化不大；Base 系列则表现出更明显的轨迹收缩和前缀稳定化。尤其在 Base-Full 与 Base-OneShot 的对比中，训练后期的 entropy 降幅和 top-1 概率增幅都清晰可见。




图 15：固定题目在不同检查点上的保留轨迹。该图直观展示了训练后前缀组织与终止行为的变化。




图 16: 固定题目的 token 级熵、概率与长度等指标随检查点的变化。该图更适合支持“训练改变了早期 token 组织方式”的解释。

表 5 与表 6 进一步给出该固定题目的数字证据。首先，在 final checkpoint 上，Base-Full 的平均 entropy 为 0.2036，而 Instruct-Full 仅为 0.0778；对应的 top-1 概率分别为 0.9246 和 0.9705。其次，从 step 0 到 final，Base-Full 与 Base-OneShot 的 logprob 增量和 entropy 下降幅度都远大于 Instruct 系列。这说明 Base 模型的训练变化确实更剧烈，也更符合一次显著行为校准的特征。图 15 与图 16 提供了与这些数值一致的可视化证据。

表 5: 固定题目在 final checkpoint 上的 token 级摘要

设置	correct?	traced tokens	entropy	top1 prob	top5 mass
Base-Full	correct	768	0.2036	0.9246	0.9970
Base-OneShot	correct	672	0.2005	0.9248	0.9970
Base-OneShot	wrong	96	0.2435	0.9056	0.9977
Instruct-Full	correct	768	0.0778	0.9705	0.9998
Instruct-OneShot	correct	768	0.1119	0.9580	0.9996

表 6: 固定题目从 step 0 到 final 的 token 级变化量

设置	$\Delta \logprob$	$\Delta \text{entropy}$	$\Delta \text{top1 prob}$
Base-Full	+0.3673	-0.3908	+0.0762
Base-OneShot	+0.3849	-0.3885	+0.0740
Instruct-Full	+0.0744	-0.0760	+0.0268
Instruct-OneShot	+0.0435	-0.0419	+0.0143

5.5.3 与主结果结论的衔接

这些 token 图并不替代主结果，而是增强主结果的解释力。宏观统计已经显示：Base 模型收益大，Instruct 模型收益小；token 级补充材料进一步表明，这种差异体现在前缀组织方式、分布收缩和正确结束行为上。二者共同形成一条较完整的证据链。

5.5.4 前缀分布的重新组织

如果将注意力集中到最终答案附近，前面的结论已经足以说明训练后分布更加稳定；但若进一步考察输出前缀的位置级分布，则能够看到更具体的变化方向。图 17 展示了 final checkpoint 上不同设置在前缀 token 区域的曲线差异。它的价值在于把“最终答对”拆解为“是否从输出前缀就沿着更稳定的轨道展开”。对于 Base 家族而言，这一点尤其重要，因为它们的改进并不是只发生在最后一两个答案 token 上，而是从更早的前缀阶段就开始体现为更低的熵和更集中的 top-1 概率。

图 17 与前面的动态聚合曲线能够相互印证。聚合统计表明，Base 家族在检查点级统计上持续收缩；前缀图进一步说明，这种收缩并不是平均到所有位置后才显现，而是在输出早期就已经发生。对于数学推理任务，这意味着模型更快地进入正确的结构化推理轨道，而不是先经过一段模糊、犹豫的路径，再在答案末端临时纠正。




图 17: final checkpoint 上不同设置在前缀 token 区域的曲线差异。该图用于说明训练后前缀组织本身发生了系统变化，而不仅仅是末尾答案更稳定。

5.5.5 从初始到终点的局部 token 分布收缩

图 18 把关注点放到训练前后差值本身。相比只看 final checkpoint，该图更适合刻画模型变化是整体轻微改善，还是集中在若干关键位置的明显分布重排。Base 条件的变化幅度远大于 Instruct 条件，尤其是在早期和中段 token 区域，logprob 上升与 entropy 下降同时出现。这与前文关于 Base 快速校准、Instruct 局部调整的解释一致。

$n=1$ 设置的结果也可以从这类图里得到补充。虽然完整轨迹图本身不是为该设置单独生成的，但它所呈现的变化模式与聚合结果相匹配：训练能够让 Base 模型在 token 级分布上变得更稳，而当 group size 缩小后，这种分布清理仍然发生，却不如 $n=8$ 那样充分。也正因为如此，正文里关于 group-relative signal 的判断并不是仅仅依赖一个汇总分数，而是有来自局部 token 变化形态的间接支撑。




图 18: 从初始到终点的 token 级变化。

5.5.6 按正确性分组的分布分离

为检验分布收缩是否真正对应更高的任务成功率，本文在保留 token-diagnostics 摘要的 validation records 上按响应正确性分组，比较 mean token entropy 与 mean top-1 probability。图 19 汇总了四个非坍塌设置在 final checkpoint 的 64-sample 摘要统计，并沿训练过程跟踪了 Base $n=1$ 。结论方向高度一致：正确响应系统性位于更“收缩”的一侧，即 entropy 更低、top-1 probability 更高。

从 final checkpoint 的跨设置比较看，这种分离在四个非坍塌条件下均可观测。具体而言，Base $n=8$ 的正确组与错误组 mean token entropy 分别为 0.165 和 0.237，Base $n=1$ 为 0.159 和 0.570，Base weak-reg. 为 0.152 和 0.172，Instruct $n=8$ 为 0.087 和 0.499；对应的 mean top-1 probability 则分别为 0.939/0.925、0.941/0.878、0.945/0.940 和 0.968/0.925。尽管不同条件下的分离幅度并不相同，但方向完全一致。这说明正文中反复出现的 entropy 收缩和置信度集中并非与任务无关的表面现象，而是与最终解题成功率稳定相关。

训练过程中的分组统计进一步表明，这一关系并非只出现在终点 checkpoint。Base $n=1$ 在 step 0 时，正确组与错误组的 mean token entropy 已呈现 0.353 与 0.880 的明显差异；到 final checkpoint，该差异对应为 0.159 与 0.570。与此相应，mean top-1 probability 从 step 0 的 0.895/0.822 提升到 final checkpoint 的 0.941/0.878。换言之，正确性分组下的分布分离贯穿训练过程，而不是某个局部 traced subset 的偶然现象。随机错误奖励设置由于 final checkpoint 已无正确响应，因此未纳入该图。

本节从两个层次回答机制问题：宏观行为指标展示整体稳定化方向，token 级轨迹则说明这种变化也能在生成内部结构中观察到。因此，这部分证据并不是额外堆叠的图表，而是在不同粒度上支撑同一个“快速行为校准”解释。




图 19: 按正确性分组的 token 分布统计。上排比较四个非坍塌设置在 final checkpoint 的正确组与错误组；下排展示 Base $n=1$ 在训练过程中的同类分组统计。

6 小组规模与奖励信号分析

6.1 $n=1$ 小组规模消融的解释边界

Base $n=1$ 在与 Base $n=8$ 相同的验证协议下表现出明确收益。其分数从 0.3630 提升到 0.5470，best score 为 0.5590，说明将 group size 降到 1 仍可产生实质改进；但在相同验证设置下，它稳定落后于 $n=8$ 的 0.5733 / 0.5753。这意味着当前证据并不支持“group size 无关紧要”的解释，而更支持如下判断：group-relative signal 并非收益存在的必要条

件，但对于获得更高、更稳定的最终收敛结果具有重要作用。

这一结论仍需谨慎解释。 $n=1$ 与 $n=8$ 的对比目前仍基于单次训练结果，因此更适合作为支持性证据，而非多 seed 意义下的最终结论。

6.2 随机错误奖励设置的解释意义

随机错误奖励设置的核心目的，是检验正常奖励条件下的收益是否真正依赖于有意义的训练信号。如果把奖励系统性破坏后，模型仍能复现正常奖励收益，那么“训练确实利用了有效监督结构”这一解释就会被显著削弱；反之，如果破坏性奖励导致性能和分布同时坍缩，那么正常奖励条件下的改善就更可以被解释为对真实训练信号的响应。

表 7: 随机错误奖励设置的终点行为

指标	数值
final score	0.00025
final response length	1192.4
final tail confidence	0.0001
final low-confidence ratio	1.0000
final token entropy	11.5466
final EOS probability	0.0009
final top-1 probability	0.0021

Base random-reward 与正常奖励设置呈现出截然不同的结果。它从 0.3630 起步，却在训练过程中迅速坍缩到 0.00025；与此同时，响应长度从 762.8 增长到 1192.4，low-confidence token 比例升到 1.000，token entropy 升到 11.5466，EOS 结束概率降到 0.0009，平均 top-1 概率也几乎退化为均匀分布水平。表 7 汇总了这种终点崩解状态。就论文论证而言，这是一条关键证据：当奖励信号被系统性破坏后，模型不会复现正常奖励条件下的收益，而是失去稳定生成能力。需要强调的是，该设置不是“无信号”消融，而是主动注入随机错误奖励的更极端奖励破坏对照；因此它能说明错误奖励会破坏收益，但不能单独等价于“没有奖励信号”的情形。

7 训练动态与证据综合

7.1 收益的阶段分布

仅知道 final score 较高，还不足以说明训练过程是否健康。更有解释力的问题是收益的阶段来源：主要来自前期快速提升，还是来自后期缓慢累积。图 20 把五组设置的主分数增量拆成三个阶段：0→36、36→96 和 96→180。这种拆法虽然是经验性的，但足够把“起步纠偏”“中段巩固”和“后期波动”区分开来。

Base 正常奖励设置的主要收益集中在前两个阶段，尤其是 $0 \rightarrow 36$ 的快速提升最为明显。这与本文强调的“快速校准”一致：模型先被迅速移出初始的高熵、长拖尾状态，然后在中段继续巩固正确轨道；最后阶段的收益更有限，主要体现为小范围高位波动。相比之下，Instruct 设置几乎没有可观的阶段增益，说明其训练并不是一次明显的结构性重排，而更接近高位附近的局部调整。随机错误奖励设置则沿完全相反方向演化，其坍塌主要发生在训练前中期。




图 20: 五组设置主分数增量的阶段性分解。

7.2 最佳 checkpoint 与最终 checkpoint 的偏离

在低数据预算强化学习里，最佳点和终点往往并不相同。图 21 将这个现象拆成两个量同时展示：一是 `best score - final score` 的差值，二是最佳验证检查点所在的位置。这个图的意义在于，它把前文分散在各处的观察集中起来：虽然多个设置最终都停在 `step 180`，但真正最优的 checkpoint 常常更早出现。

这个现象对结果分析具有重要意义。它说明当前训练过程更接近“快速进入高位区间后在后期轻微振荡”，而不是单调改进过程。对 Base 模型而言，这意味着如果任务目标是获得最佳验证性能，那么早停或 checkpoint selection 都值得纳入训练策略讨论；对 Instruct 模型而言，则意味着它本来就缺乏大幅收益空间，后期训练更容易表现为噪声而不是确定性的改进。




图 21: 五组设置的最佳 checkpoint 与最终 checkpoint 对比。

7.3 终点行为排序的补充证据

图 22 对五组设置的若干终点行为指标做了统一排序，包括最终 token entropy、低置信 token 比例、top-1 probability 和响应长度。相比逐个在正文中报数字，这种图更容易看出整体格局。它表明 Base 家族内部虽然都能获得较高收益，但不同设置的“收敛风格”并不完全相同：弱正则化设置表现出更强的收缩，标准 $n=8$ 设置更为稳健， $n=1$ 则在最终熵与低置信比例上都落后于 $n=8$ ，而随机错误奖励设置则远离所有正常收敛区间。

该排序图说明论文分析不能只依赖单一 reward。若只看 final score，弱正则化设置与标准 $n=8$ 设置十分接近；但终点 token 指标并排观察后可以发现，它们在收缩强度、闭合方式和输出长度上并不相同。与此同时，随机错误奖励设置清楚展示了奖励被破坏后的崩解形态。这个对照说明，主分数与行为分布的联合分析比单个汇总数字更具有解释力。




图 22: 五组设置终点行为指标排序图。

7.4 多指标之间的耦合关系

7.4.1 收益提升与校准量的同步关系

正文已经分别讨论了主分数、行为指标和 token 补充材料。进一步需要检验的是，这些变化是否只是在方向上相同，还是在设置层面上也呈现同步耦合。图 23 将五组设置的主分数增益，分别与四类动态量的变化幅度并排展示：训练期 actor entropy 的变化量、验证期 token entropy 的变化量、低置信 token 比例的变化量，以及验证响应长度的变化量。

该图将“快速校准”从一种合理解释进一步推进为更严格的经验模式。Base 正常奖励设置并不只是 reward 提升更大，它们同时也对应更大的 entropy 收缩、更大的低置信 token 减少，以及更明显的长度压缩。Instruct 设置则整体落在另一侧：分数提升小，动态收缩也小。更关键的是，Base random-reward 落在图中的完全反方向，表现为 reward 下降、熵上升、低置信比例上升以及长度拉长。这种设置层面的同步关系表明，“收益”和“分布稳定化”并不是彼此独立的两条观察，而是在同一批结果中共同出现。




图 23: 五组设置的主分数增益与四类关键动态量变化幅度的耦合关系。

7.4.2 终点性能与终点稳定性的共同前沿

另一个重要维度是终点分数与终点分布稳定性之间的关系。图 24 将最终验证分数分别与最终 token entropy、最终低置信 token 比例放在同一张图中。虽然只有五个设置点，

但这种前沿式展示仍然很有价值，因为它把“效果更好”和“分布更稳”压缩到了同一个坐标系里。

Base 家族内部基本呈现出清晰趋势：最终分数更高的设置，通常也对应更低的 entropy 与更低低置信 token 比例。Base $n=1$ 在这两个坐标上都明显落后于 Base $n=8$ ，因此它的劣势不是只体现在某一条 reward 曲线上，而是体现在终点分布质量本身。Instruct 家族则落在另一块区域：它们整体分数更高，但内部变化幅度有限，说明其收益空间本来就不大。这种分区形态进一步表明，模型先验强弱与分布稳定化程度共同决定了最终性能所处的位置。




图 24：最终验证分数与最终稳定性指标的联合前沿图。

7.4.3 跨指标图的证据作用

如果将这些图与前文结合起来考察，全文的证据组织可以归纳为更严密的三层结构。第一层是主分数与 best checkpoint，说明训练确实带来了可观收益；第二层是长度、entropy、top-1 probability、EOS 和 low-confidence ratio 的动态变化，说明收益伴随可解释的行为重排；第三层就是本节的耦合图 and 前沿图，它们把不同指标重新放回设置层面上联合观察，从而证明这些现象在设置层面也是同步的。由此，本节回答训练动态与证据综合问题：收益主要在前中期形成，后期进入高位波动区间，并且这种收益与分布稳定化在设置层面保持同步。

8 讨论

8.1 主要支持证据

本文的主要支持证据不是单个分数，而是一组相互支撑的现象：Base 模型的正确率显著提升，响应长度缩短，尾部置信度提升，低置信 token 比例下降，token entropy 下降，EOS 概率上升，token 级补充材料中也能看到前缀组织和分布收缩的明显改善。这些现象共同指向同一个解释：1-shot GRPO 对 Base 数学推理模型的主要作用，是把已有能力更快地校准到更稳定的输出轨道上。

8.2 当前限制

当前限制也较为明确。第一， $n=1$ 与 $n=8$ 的同口径比较仍是单次训练结果，尚未形成多 seed 稳健性证据。第二，随机错误奖励设置目前只覆盖 Base 家族，尚缺与之匹配的 Instruct 结果。第三，当前诊断支持“快速校准”解释，但还不能完全分离校准与跨题型、跨难度的知识获得；更直接的后续测试应按题目难度或知识领域分层，检验收益是较均匀地出现，还是集中在特定知识区域。第四，全量数据结果目前被定位为经验上界参考，而不是与表 1 完全同口径、同诊断覆盖的比较项。第五，token diagnostics 虽然覆盖到每个检查点的 64 个诊断样本，但完整 token 轨迹只对其中 8 条样本落盘，因此宏观结论仍应主要建立在逐样本验证均值上，而不是依赖少量固定题目的 token 轨迹。

8.3 外推边界

这些限制并不改变主结论，但限定了它的外推范围。当前证据足以支持“Base 模型在 1-shot GRPO 下出现显著收益并伴随行为分布稳定化”，但不宜进一步声称 group size 差异已经具备多 seed 级别的稳健性，也不宜把 Base 家族中的随机错误奖励结论直接外推到 Instruct 家族。类似地，全量数据结果适合作为经验上界参考，而不是与五组主结果完全同口径的横向比较项。

8.4 当前证据链汇总

为了避免正文在最后阶段重新退化成孤立的汇总数字，表 8 对当前最重要的判断做了集中汇总。它的作用不是重复前文，而是把“结论判断、主要证据和仍需保留的边界”放在同一张图景里，方便读者在结尾快速把握证据链。

表 8: 当前关键结论的证据状态汇总

结论判断	主要证据	仍需保留的边界
1-shot GRPO 对 Base 数学推理模型有效	主分数曲线、Base 正常奖励设置约 0.20 的绝对提升、行为指标同步改善	仍需更多 seed 检验其跨随机初始化与采样噪声的稳定性
1-shot 低数据收益低于全量数据经验上界	Base/Instruct 全量数据结果均高于对应 1-shot 结果, Base final 差距约 0.0300, Instruct final 差距约 0.0143	全量数据结果目前是经验上界参考, 不属于表 1 的同口径比较项
收益更符合快速校准而非知识注入	response length 缩短、entropy 下降、low-conf 降低、top-1 与 EOS 上升、固定题目轨迹证据支持	当前诊断尚不能完全区分校准与跨题型、跨难度知识获得
group-relative signal 对最佳结果有帮助	n=1 在 matched validation protocol 下稳定落后于 n=8	目前仍是单次训练结果, 尚缺多 seed 复验
奖励破坏会破坏训练收益与分布稳定化	Base random-reward 中 score 坍塌、entropy 爆炸、low-conf 饱和、EOS 与 top-1 置信度崩解	该设置属于极端错误信号对照, 不是纯无信号消融; 且当前仅在 Base 家族上完成验证

9 结论

本文围绕 1-shot GRPO 在数学推理任务中的作用机制，构建了一个由五组关键设置和一组全量数据上界参考共同组成的证据框架。主结果表明，在 Qwen2.5-Math-1.5B 上，1-shot GRPO 可以带来接近 0.20 的显著分数提升，并伴随响应长度缩短、尾部置信度上升、token entropy 下降、低置信 token 减少以及结束行为更果断等一系列同步变化；而在 Qwen2.5-Math-1.5B-Instruct 上，训练效应则明显更接近高位微调。全量数据参考进一步说明，Base 家族对训练范式与奖励结构更为敏感，Instruct 家族的绝对收益整体更温和，同时 1-shot 结果虽有意义但仍低于全量数据经验上界。

综合主结果、动态指标、token 级补充证据与随机错误奖励设置，本文认为当前最稳妥的结论有三点。第一，1-shot GRPO 对 Base 数学推理模型是有效的。第二，这种收益更适合被解释为快速校准，而非知识注入；不过，完全分离二者仍需要按题目难度或知识领域分层的后续评估。第三，group-relative signal 与奖励结构都会影响最终收敛上限：将训练 group size 从 8 降到 1 会削弱但不会消除收益，而一旦奖励信号被系统性破坏，模型不仅不会复现正常奖励条件下的收益，反而会在分数与行为分布上同步崩解。当前仍需保留的边界在于，n=1 与 n=8 的同口径比较仍是单次训练结果，随机错误奖励设置也尚未扩展到 Instruct 家族。在这些边界内，现有证据已经支持将 1-shot GRPO 理解为一种主要作用于分布稳定化与行为校准的低数据强化学习机制。

A 附录：补充讨论

关于 Base 模型收益的补充说明 在当前设置下，1-shot GRPO 对 Base 数学推理模型的作用主要体现为行为分布的稳定化，而非简单拉长推理链。模型在训练后显著缩短输出长度、降低 token entropy、减少低置信 token，并更果断地结束答案，这些现象共同支持“快速校准”解释。

关于 Instruct 模型收益较小的补充说明 Instruct 模型在 step 0 已经具备较高的数学推理先验，因此 1-shot GRPO 的作用更接近局部微调与分布调整，而不是大幅纠偏。这也是其收益量级明显小于 Base 模型的主要原因。

关于 n=1 结果的补充说明 n=1 小组规模消融结果说明，将 group size 降到 1 并不会阻止模型获得显著收益；但在与 n=8 相同的评估口径下，它仍然系统性落后于 n=8，因此当前证据更支持“group-relative signal 对最佳效果有帮助”这一判断。

关于随机错误奖励设置的补充说明 Base 随机错误奖励设置直接采用错误奖励构造破坏性监督。结果显示，模型在该设置下不仅无法复现正常奖励条件下的收益，反而出现分数坍缩、熵爆炸、长度异常增长与停止行为失稳。这说明正文中的收益确实依赖于有意义的训练信号，而不是训练流程本身的偶然产物。

关于全量数据参考结果的补充说明 除正文主结果外，全量数据与格式约束结果也提供了一组有价值的补充参照。它们虽然不宜并入表 1，但能够增强论文对“训练模式差异”和“奖励结构差异”的讨论。表 9 汇总了其中最具代表性的几条参考结果。整体上看，Base 家族中 full 训练明显强于 1-shot；Instruct 家族中也存在同方向差异，但绝对幅度更小。与此同时，一个格式约束主导参考仅从 0.3630 提升到 0.4490，明显弱于常规奖励路径，这使其适合作为正文外的辅助参照。

表 9：全量数据与格式约束参考结果汇总

模型家族	设置	初始	final	best
Base	1-shot	0.3630	0.5753	0.5803
Base	full	0.3630	0.6053	0.6135
Base	格式约束主导参考	0.3630	0.4490	0.4785
Base	1-shot entropy 参考	0.3630	0.5698	0.5835
Instruct	1-shot	0.6860	0.6928	0.6985
Instruct	full	0.6860	0.7070	0.7070
Instruct	1-shot 参考	0.6860	0.6893	0.7005
Instruct	full 参考	0.6795	0.7118	0.7118

这些结果更适合作为附录层面的参考材料，而不应与正文主结果表直接合并，原因在于训练文件范围与记录覆盖并不完全一致。更稳妥的写法是把它们作为“与主结论同向的补充证据”：一方面，full 普遍优于 1-shot；另一方面，格式约束较强的参考设置

只能带来有限改善，这与正文中“奖励结构和组内比较信号都会影响最终上限”的主线是一致的。对应可视化已在正文图 1 展示，附录因此只保留紧凑的数字参考，避免重复排版同一批图。

参考文献

- [1] Wang, Y., Yang, Q., Zeng, Z., Ren, L., Liu, L., Peng, B., Cheng, H., He, X., Wang, K., Gao, J., Chen, W., Wang, S., Du, S. S., & Shen, Y. Reinforcement Learning for Reasoning in Large Language Models with One Training Example. arXiv preprint arXiv:2504.20571, 2025.
- [2] Luo, M., Tan, S., Wong, J., Shi, X., Tang, W. Y., Roongta, M., Cai, C., Luo, J., Li, L. E., Popa, R. A., & Stoica, I. DeepScaleR: Surpassing O1-Preview with a 1.5B Model by Scaling RL. Notion Blog, 2025.
- [3] DeepSeek-AI et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. arXiv preprint arXiv:2501.12948, 2025.
- [4] Kimi Team et al. Kimi k1.5: Scaling Reinforcement Learning with LLMs. arXiv preprint arXiv:2501.12599, 2025.
- [5] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. Proximal Policy Optimization Algorithms. arXiv preprint arXiv:1707.06347, 2017.
- [6] Shao, Z. et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. arXiv preprint arXiv:2402.03300, 2024.
- [7] Lightman, H., Kosaraju, V., Burda, Y., Edwards, H., Baker, B., Lee, T., Leike, J., Schulman, J., Sutskever, I., & Cobbe, K. Let’s Verify Step by Step. arXiv preprint arXiv:2305.20050, 2023.
- [8] Li, Y. et al. Competition-Level Code Generation with AlphaCode. arXiv preprint arXiv:2203.07814, 2022.
- [9] Rein, D., Hou, B. L., Stickland, A. C., Petty, J., Pang, R. Y., Dirani, J., Michael, J., & Bowman, S. R. GPQA: A Graduate-Level Google-Proof Q&A Benchmark. arXiv preprint arXiv:2311.12022, 2023.
- [10] Hendrycks, D. et al. Measuring Mathematical Problem Solving With the MATH Dataset. In Advances in Neural Information Processing Systems (NeurIPS), 2021; arXiv preprint arXiv:2103.03874.
- [11] Yang, A. et al. Qwen2.5-Math Technical Report: Toward Mathematical Expert Model via Self-Improvement. arXiv preprint arXiv:2409.12122, 2024.