

低数据强化学习中的数学推理行为校准： 1-shot GRPO 的受控实验与机制分析

Behavioral Calibration for Mathematical Reasoning under
Low-Data Reinforcement Learning: Controlled Experiments and
Mechanistic Evidence for 1-shot GRPO

作者 Xu, Zihang

单位 CUHK(ShenZhen)

课程/项目 MDS5910 Capstone Project

日期 2026 年 4 月 12 日

摘要

本文研究极低数据强化学习场景下 1-shot GRPO 对数学推理模型的作用机制。近期关于 1-shot RLVR 的研究表明,即使只使用一个带可验证奖励的训练样本,强化学习仍可能显著提升数学推理表现 [1]。在这一发现的基础上,本文在 Qwen2.5-Math-1.5B 与 Qwen2.5-Math-1.5B-Instruct 上构建七组主结果设置,并将七组设置全部纳入聚合行为与 token diagnostics 分析;其中训练期 actor entropy 和固定题目完整轨迹则按可用记录范围作为补充证据使用。全文结合验证正确率、响应长度、置信度、熵和停止行为等指标分析训练后的生成分布变化。

结果呈现出清晰的模型家族差异:Base 模型在有意义奖励监督下获得约 0.20 的验证分数提升,而 Instruct 模型由于起点更高,只表现出小幅局部变化。将训练 group size 从 $n=8$ 降到 $n=1$ 会削弱但不会消除收益;采用随机错误奖励时,Base 模型不再复现正常奖励条件下的提升,而是在分数与行为指标上同步坍缩。除主分数外,Base 模型在正常奖励条件下还同时表现出响应长度缩短、答案尾部置信度上升、低置信 token 比例下降、token entropy 下降以及 EOS 结束概率上升等一致变化。

这些结果支持一个直接解释:在当前设置下,1-shot GRPO 对 Base 数学推理模型的主要作用是快速行为校准,而不是注入额外数学知识。本文的贡献在于提供了 group size 与奖励有效性的同口径比较、围绕分布稳定化的多指标证据链,以及与 one-shot 共享训练日程和验证口径的 full-data 对照结果。

关键词: 低数据强化学习; 数学推理; 行为校准; GRPO; 奖励破坏; token 级诊断

English Abstract

This paper studies 1-shot GRPO for mathematical reasoning under an extremely low-data reinforcement-learning regime. Motivated by recent evidence that verifiable reward can remain effective with a single training example [1], it asks what kind of generation behavior changes when the data budget is so small. The primary comparison covers seven settings across Base and Instruct model families, and all seven settings are included in the aggregate behavioral and token-diagnostic analysis; training-time actor entropy and fixed-prompt full traces are used according to their available coverage. The analysis combines validation accuracy with diagnostics for length, confidence, entropy, and stopping behavior.

The main finding is a strong asymmetry across model families. The Base model gains roughly 0.20 validation score under meaningful reward supervision, while the Instruct model moves only slightly from an already strong starting point. Reducing the training group size from $n=8$ to $n=1$ weakens but does not remove the gain, and reward corruption causes the Base model to collapse rather than reproduce the meaningful-reward improvement. Across the successful Base settings, training also shortens outputs, lowers entropy, reduces low-confidence token mass, raises tail confidence, and makes stopping behavior sharper. These results support interpreting 1-shot GRPO primarily as fast behavioral calibration for the Base math model.

Keywords: low-data reinforcement learning; mathematical reasoning; behavioral calibration; GRPO; reward corruption; token-level diagnostics

目录

1	引言	1
2	方法背景与研究问题	2
2.1	GRPO 的基本思想	2
2.2	最终正确率之外的诊断指标	2
2.3	研究维度与核心假设	2
3	研究设置	3
3.1	模型、数据与总体流程	3
3.2	主结果设置	3
3.3	训练与评估口径	4
3.4	matched full-data 对照	4
4	主结果：1-shot GRPO 的有效性	5
4.1	总体趋势：Base 收益显著，Instruct 收益有限	5
4.2	Base 模型：收益大且具有一致性	7
4.3	Instruct 模型：高起点与小增益	8
4.4	最佳检查点与最终检查点的偏离	8
5	行为证据：宏观指标与 token 级证据	9
5.1	Base 模型的收缩与稳定化	9
5.2	七组设置的聚合 token 诊断	9
5.3	动态统计进一步强化了上述判断	14
5.4	弱约束版本的启示	17
5.5	Instruct 模型主要是局部微调	17
5.6	Token 级补充证据	18
5.6.1	补充材料的口径与边界	18
5.6.2	直接观察：Base 变化大，Instruct 变化小	18
5.6.3	与主结果结论的衔接	20
5.6.4	前缀分布的重新组织	20

5.6.5	从初始到终点的局部 token 分布收缩	21
5.6.6	按正确性分组的分布分离	21
5.7	保存 checkpoint 的全量 token 离线诊断	23
6	小组规模与奖励信号分析	29
6.1	n=1 小组规模消融的解释边界	29
6.2	随机错误奖励设置的解释意义	29
7	训练动态与证据综合	30
7.1	收益的阶段分布	30
7.2	最佳 checkpoint 与最终 checkpoint 的偏离	30
7.3	终点行为排序的补充证据	31
7.4	多指标之间的耦合关系	32
7.4.1	收益提升与校准量的同步关系	32
7.4.2	终点性能与终点稳定性的共同前沿	34
7.4.3	跨指标图的证据作用	34
8	讨论	35
8.1	主要支持证据	35
8.2	当前限制	35
8.3	外推边界	35
8.4	当前证据链汇总	35
9	统一机制解释	36
9.1	从分数提升到分布稳定化	36
9.2	full-data 对照的解释位置	37
9.3	group size 与奖励结构的作用	37
9.4	正确性分组证据的作用	38
9.5	当前证据的整体边界	38
10	结论	40
A	附录：补充讨论	41

1 引言

近年来，大语言模型在数学推理、代码生成和科学问答等复杂推理任务上取得了快速进展 [3, 4, 6, 8, 9]。与纯监督微调不同，带可验证奖励的强化学习能够利用最终答案正确性或过程质量信号，在生成阶段直接优化模型的行为分布 [3, 7, 1]。对于数学推理这类任务而言，模型不仅需要“知道”相关知识，还需要在解题过程中做出一系列结构化决策：是否继续展开、是否及时纠偏、何时终止生成，以及如何在多个候选思路之间重新分配概率质量。这些问题共同决定了最终正确率的上限，也使得基于强化学习的推理优化成为近年研究中的重要方向。

Wang 等人关于 1-shot RLVR 的近期工作进一步把这一问题推向了极低数据场景 [1]。该工作表明，对于 Qwen2.5-Math-1.5B 这样的数学模型，使用单个经过选择的训练样本也可以在 MATH500 以及多个数学推理基准上带来显著提升，并且在某些设置下接近使用更大 RLVR 数据子集得到的效果。更重要的是，该工作同时讨论了 outcome reward 与 format reward 的区别、policy-gradient loss 的主要作用、探索项的重要性，以及训练样本准确率饱和后测试性能仍可继续提升的 post-saturation generalization 现象。这些发现说明，1-shot RLVR 并非孤立的经验现象，而是一个值得进一步开展机制分析的研究场景。

本文沿着上述问题继续展开，但重点从“单样本 RLVR 是否存在显著基准收益”转向“这种收益对应怎样的行为变化”。在当前实践中，GRPO 提供了一种尤其适合推理模型的优化思路。它并不依赖于高精度 critic，而是通过同一输入下多个采样响应之间的相对比较构造训练信号。对于数学题而言，这种组内比较非常自然：同一道题通常可以采样出完全正确、部分正确和明显错误的多条解法，组内差异恰好为训练提供了可利用的排序信号。因此，GRPO 不仅是一种可行的优化方法，也使 group size 本身成为可以被直接检验的机制变量。

在极低数据预算下，GRPO 对模型行为的影响需要更细的受控比较来刻画。本文关注三个问题：1-shot GRPO 是否主要改变已有推理行为而不只是提高分数；这种变化在 Base 与 Instruct 先验之间是否不同；以及它是否依赖 group-relative signal 和有效奖励信号。由此，本文引入 token-level diagnostics、相同验证口径的 $n=1$ 设置和随机错误奖励设置，用于把低数据 RLVR 从单纯分数比较推进到行为机制分析。

围绕这些问题，本文的主要贡献可以概括为三点。第一，本文在 1-shot RLVR 研究脉络下，统一比较七组关键结果设置，并将 $n=1$ 小组规模设置、随机错误奖励设置以及两组 matched full-data 对照纳入同一结果框架。第二，本文不仅比较最终 score，还系统整理了多种行为指标与训练过程中的动态统计，从而给出“训练如何改写推理分布”的直接证据。第三，本文进一步把 full-data 结果从附属参考提升为主结果对照，用于评估 1-shot 收益在同一训练日程下距离更大数据预算结果还有多远。后文将依次给出方法背景、研究设置、主结果、行为证据、token 级证据与训练动态综合。

2 方法背景与研究问题

2.1 GRPO 的基本思想

GRPO 的核心在于组内相对比较。对于同一条输入，训练阶段会采样多个候选响应，并依据它们的相对表现形成优势信号。相比传统 PPO 强依赖的状态价值估计，这种做法减少了显式 critic 的复杂度，也更贴近推理任务中的真实训练需求。对于数学推理而言，多个采样结果之间常常体现出清晰的质量差异，例如某些响应中途走偏、某些响应拖尾过长、某些响应则能在较短链路内稳定闭合答案。GRPO 正是利用这些组内差异重新分配概率质量，让下一轮采样更偏向“结构更好”的解法。

在本文整理的主结果中，标准配置采用 `rollout_n=8`。这意味着每个输入在训练阶段会被采样 8 次，以形成组内比较信号。与之对应，Base `n=1` 设置仅把训练阶段的 `rollout_n` 降为 1，同时保持 `val_rollout_n=8` 与 Base `n=8` 一致，用来更直接地测试组内相对信号在当前任务中的作用。由于其他超参数大体保持一致，这种设计使得 group size 成为更直接的主要变量。

2.2 最终正确率之外的诊断指标

仅比较最终 score 会得到过于粗略的结论：Base 模型收益显著，而 Instruct 模型收益有限。然而，这一结论无法解释训练对生成行为的具体影响。为此，本文引入了多种验证期行为指标，包括平均响应长度、答案尾部置信度、低置信 token 比例、token 熵、最终 EOS 概率和平均 top-1 token 概率。它们分别对应模型行为的不同侧面：更短的响应可能意味着推理链更加收敛；更低的 entropy 和更高的 top-1 概率意味着分布更集中；更高的 EOS 概率则表明模型更擅长在恰当位置结束生成。

这些指标能够把“性能提升”拆解成“行为变化”。本文将“行为校准”操作性定义为：在验证正确率提升的同时，模型生成分布朝更短响应、更低 token entropy、更少低置信 token、更高尾部与 top-1 置信度，以及更清晰 EOS 结束行为的方向同步移动。这个定义描述的是可观测的分布变化，并不等同于声称模型学习了新的数学事实。

2.3 研究维度与核心假设

本文围绕以下五个研究维度展开：

- 1-shot GRPO 在数学推理任务上带来的可重复性能提升。
- Base 模型与 Instruct 模型之间的收益规模差异。
- 训练收益与 entropy、低置信 token 比例和 EOS 结束行为之间的系统关联。
- 受扰动训练信号对正常奖励收益的削弱程度。
- 将 group size 从 8 降到 1 后，组内相对信号减弱对训练改进的影响。

对应地，本文采用如下假设作为分析线索：第一，1-shot GRPO 更符合快速校准机制，而不是能力注入机制；第二，先验更弱的 Base 模型收益空间更大；第三，行为层指标会与主分数共同变化；第四，随机错误奖励设置不应复现正常奖励条件下的收益；第五，若 group-relative signal 很关键，则 $n=1$ 应表现出明显衰减。后文的结果分析将围绕这些假设逐条展开。

3 研究设置

3.1 模型、数据与总体流程

本文涉及两类模型：Qwen2.5-Math-1.5B 与 Qwen2.5-Math-1.5B-Instruct。验证集统一采用 MATH500，训练模式统一为 one-shot 设定。虽然这里的 one-shot 并不意味着只有单条样本，而是指训练数据规模被压缩到极低预算，但这一设置与本文关注的低数据强化学习机制问题相匹配。

从设置配置可以看出，各条件在学习率、batch size、`test_freq` 和总 epoch 数上具有较高一致性，主要变化集中在三类因素上：模型先验（Base 或 Instruct）、正则化强度（标准或弱正则化）以及 group size ($n=8$ 或 $n=1$)。这意味着不同设置之间具备较好的对照价值。

3.2 主结果设置

表 1 汇总了七组设置的核心结果，具体标签见表中。两组 full-data 结果与对应 one-shot baseline 共享验证集、`rollout_n=8`、batch size 与 `test_freq`；主差异是训练数据由单样本 `pi1_one_ans.parquet` 扩展为 `train.parquet`。

表 1: 七组主结果设置的核心分数比较

设置	初始	final	增量	最佳检查点	best score
Base $n=8$	0.3745	0.5733	+0.1988	156	0.5753
Base full-data ^b	0.3745	0.6105	+0.2360	180	0.6105
Base $n=1$ ^a	0.3630	0.5470	+0.1840	174	0.5590
Base weak-reg.	0.3745	0.5747	+0.2002	174	0.5765
Base random-reward ^c	0.3630	0.0003	-0.3628	0	0.3630
Instruct $n=8$	0.6837	0.6873	+0.0035	162	0.6995
Instruct full-data ^b	0.6837	0.7018	+0.0180	144	0.7063

^a Base $n=1$ 采用与 Base $n=8$ 相同的 `val_rollout_n=8` 设置，因此每个验证检查点同样约 4000 条记录，可直接进行同口径比较。

^b 两组 full-data 结果与对应 one-shot baseline 共享相同验证口径与训练日程；主要差异是训练文件由 `pi1_one_ans.parquet` 改为 `train.parquet`。

^c Base random-reward 采用随机错误奖励构造，定位为奖励破坏设置，而不是无奖励设置。

3.3 训练与评估口径

主结果中的七组设置都覆盖 step 0 到 step 180，步长为 6。每个检查点的结果均由逐样本验证记录聚合得到，且每组都采用约 4000 条验证记录，因此主分数曲线、最佳检查点和检查点级波动具备较好的可比性。尤其是 Base n=8 与 Base full-data、Instruct n=8 与 Instruct full-data，共享相同验证采样口径和训练日程，可直接用来衡量数据预算扩大后的收益增量。

后文采用分层诊断口径。聚合行为指标与 token diagnostics 覆盖七组主结果设置，因此两组 full-data 实验不仅作为分数级对照，也进入终点 token 指标、正确性分组统计和 one-shot/full-data 对比分析。训练期 actor entropy 曲线仍主要覆盖五组低数据与控制条件，因为这部分依赖训练日志字段；固定题目的完整 token 轨迹也只覆盖较窄的保留子集。更准确地说，每个检查点最多有 64 个样本参与 token-level diagnostics 聚合统计，但只有其中 8 条样本会额外保存完整的 token_diagnostics 轨迹。对于主 n=8 设置，这 8 条完整轨迹通常对应同一固定题目的 8 次采样，因此完整轨迹更适合作为机制证据，而不适合作为“全任务统计结论”。

3.4 matched full-data 对照

两组 matched full-data 结果使本文能够在同一训练日程下直接比较 one-shot 与更大数据预算。以 Base 家族为例，Base full-data 从 0.3745 提升到 0.6105，相比 Base n=8 的 0.5733 多出 0.0373 的 final 分数；在最佳 checkpoint 上，差距为 0.0353。Instruct 家族同样呈现相同方向，但绝对差距较小：Instruct full-data 的 final 为 0.7018，相比 Instruct n=8 的 0.6873 高出 0.0145，最佳 checkpoint 差距为 0.0068。

这里的 full-data 沿用 1-shot RLVR 原文的数据口径，指从 DeepScaleR-Preview-Dataset 抽取的 DSR-sub 训练池；one-shot 指同一 DSR-sub 中被选出的单个样本 π_1 [1, 2]。由于当前这两组 full-data 运行与对应 one-shot baseline 共享 rollout_n=8、验证集、batch size 与 test_freq，它们可以被视为“仅扩大训练数据预算”的 matched 对照。

这组 matched 对照使主结果叙事更完整。第一，它表明“Base 家族收益显著、Instruct 家族收益有限”的结论在扩大数据预算后仍然保持相同方向。第二，它更精确地定位了 one-shot 的上限位置：1-shot 并非无效，但在同一训练日程下通常仍低于 full-data。第三，它说明数据预算的边际收益具有明显的模型家族差异，Base 家族从 full-data 中获得的附加收益更大，而 Instruct 家族的提升更接近温和增量。

表 2: 同口径 one-shot 与 full-data 的分数差距

模型家族	1-shot final	full final	final 差距	best 差距
Base	0.5733	0.6105	+0.0373	+0.0353
Instruct	0.6873	0.7018	+0.0145	+0.0068

注：差距定义为 full-data 结果减去对应 one-shot baseline 结果。当前两组对照共享验证口径与训练日程，主差异为训练数据预算。




图 1: Base 与 Instruct 家族中 one-shot 和 full-data 的初始、终点与最佳分数对照。Matched full-data 结果显示，扩大数据预算在两类模型上都能带来收益，但 Base 家族的增量更大。

表 2 和图 1 因而不只是附属参照，而是主结果的重要补充部分。它们直接回答了一个此前无法严格回答的问题：在相同验证口径与训练日程下，把数据预算从 one-shot 扩展到 full-data 后，收益还能增加多少。当前答案是明确的，即两类模型都继续获益，但 Base 家族的边际提升更大。

4 主结果：1-shot GRPO 的有效性

4.1 总体趋势：Base 收益显著，Instruct 收益有限

表 1 呈现出三个主要现象。第一，Base 模型在多个 one-shot 设置中都表现出接近 0.20 的绝对分数提升，说明 1-shot GRPO 在弱先验数学模型上能够产生稳定而显著的收益。第二，在 matched full-data 对照下，Base 家族的终点分数进一步提升到 0.6105，而 Instruct 家族只从 0.6873 提升到 0.7018，显示数据预算扩展后的边际收益仍然存在明显家族差异。第三，随机错误奖励会使 Base 模型在分数上直接坍塌，从而把“有意义奖励”与“训练流程本身”区分开来。




图 2: 七组主结果设置的 validation score 随训练检查点变化。Matched full-data 曲线表明，在 Base 与 Instruct 两个家族中，扩大训练数据预算都能继续提高分数，但 Base 家族的增量更大。

图 2 强化了表格中的结论。Base 系列从较低起点快速上升，并在中后期进入相对平稳的高位区间；其中 Base full-data 进一步把终点抬高到 0.6105。Instruct 系列则从一开始就处于较高水平，后续训练带来的变化幅度明显更小，即便扩展到 full-data，收益也仍然属于温和增量。这意味着不能用同一个收益尺度评价两类模型。对于 Base 模型，训练是在帮助它脱离“高熵、长拖尾、低置信”的初始状态；对于 Instruct 模型，训练更接近在已有较强先验上的局部调整。




图 3: 七组主结果的局部放大视图：左图比较 Base 家族中的 one-shot 与 full-data 条件，中图比较 Instruct 家族中的 one-shot 与 full-data 条件，右图单独显示随机错误奖励对照。

由于七组设置的分数量级差异较大，单独依赖图 2 容易压缩局部差异。图 3 因而承担一个补充角色：左图把 Base 家族中四条成功曲线放在相近尺度上，能够更清楚地看到 Base full-data 明显高于 one-shot 条件，而 Base n=1 则稳定偏低；中图表明 Instruct

模型即便在较高起点上，full-data 仍能带来可辨认但有限的增量；右图把随机错误奖励条件下的坍缩单独展开，从而避免它在总览图里仅仅表现为“贴近零值的一条线”。

4.2 Base 模型：收益大且具有一致性

Base $n=8$ 从 0.3745 提升到 0.5733，说明标准设定下的 1-shot GRPO 已经足以将基础数学模型从较不稳定的初始状态提升到更高性能区间。更值得注意的是，这一收益并不是孤例。Base weak-reg. 的 final score 为 0.5747，与标准设置非常接近；而 Base random-reward 却从 0.3630 快速坍缩到 0.00025。二者构成一组更具解释力的对照：当奖励结构保持有效时，Base 模型的收益具有较强一致性；而当奖励信号被系统性破坏后，这种收益不会出现。




图 4: Base 家族四组设置的主分数变化。三个正常奖励方向设置表现出前中期快速上升，而随机错误奖励设置则快速失稳。




图 5: Instruct 家族 $n=8$ 设置的主分数变化。曲线整体维持在高位，训练主要表现为小幅波动与局部微调。

图 4 与图 5 进一步说明，Base 家族的多个设置虽然有不同后期波动，但都共享一种相似的学习形态：前中期快速上升，后期进入缓慢振荡；Instruct 家族则主要维持在高位窄幅波动。这提示在极低数据预算下，最佳 checkpoint 未必总是最终 checkpoint；在结果分析中区分二者是有意义的。

4.3 Instruct 模型：高起点与小增益

Instruct $n=8$ 在 step 0 就达到 0.6837，这一数值远高于 Base 模型的起点。训练后的 final score 为 0.6873，最佳检查点为 162，best score 为 0.6995。若只看数值，它仍然是一个有效设置，但其收益量级只有 0.0035，与 Base 模型约 0.20 的绝对提升完全不在同一量级。

因此，更准确的叙事不是“1-shot GRPO 对所有模型都同样有效”，而是“1-shot GRPO 的收益高度依赖于模型起点”。对于高先验 Instruct 模型，训练已经很难带来显著的结构性能收益；对于先验较弱的 Base 模型，训练空间则大得多。

4.4 最佳检查点与最终检查点的偏离

另一个不可忽略的观察是，多个设置的最佳分数并不出现在最终 step 180。例如，Base $n=8$ 的最好结果出现在 step 156，Base weak-reg. 出现在 step 174，Instruct $n=8$ 的最佳检查点则是 162。这一现象说明在当前训练预算下，模型的收益并不是单调累积的；相反，训练中后期可能进入高位波动区间。因此，在结果分析中区分“最终 checkpoint”和“最佳 checkpoint”是必要的。

5 行为证据：宏观指标与 token 级证据

5.1 Base 模型的收缩与稳定化

仅比较 score 可以确认 Base 模型收益，但不足以解释收益的行为来源。行为指标提供了更直接的机制证据。表 3 显示，Base n=8 在最终阶段的平均 response length 为 603.1，相比起点明显缩短；答案尾部置信度提升到 0.9331；低置信 token 比例降到 0.0325；token entropy 降到 0.1839；最终 EOS 概率上升到 0.9880。这组变化表明，模型较少表现为冗长试探，并更快趋于稳定闭合。

表 3：七组主结果设置的最终行为指标汇总

设置	长度	尾部置信	低置信	熵	EOS	top-1
Base n=8	603.1	0.9331	0.0325	0.1839	0.9880	0.9354
Base full-data	536.0	0.9320	0.0308	0.1718	0.9549	0.9378
Base n=1	580.4	0.9003	0.0488	0.2811	0.9215	0.9227
Base weak-reg.	578.6	0.9437	0.0294	0.1563	0.9738	0.9437
Base random-reward	1192.4	0.0001	1.0000	11.5466	0.0009	0.0021
Instruct n=8	470.3	0.9571	0.0187	0.1322	0.9926	0.9634
Instruct full-data	452.7	0.9673	0.0115	0.0837	0.9983	0.9710

注：短标签对应七组主结果设置；EOS 指最终 EOS 概率，top-1 指平均 top-1 token 概率。

这类变化与“能力注入”并不完全一致，却与“快速校准”高度吻合。短期知识学习并不必然导致长度缩短、结束概率上升和熵下降同时出现；相反，如果模型学会更稳定地组织原有解题习惯，这些指标更可能同步变化。因此，训练收益更适合被解释为对分布进行重新整形，而不是为模型引入额外知识模块。

5.2 七组设置的聚合 token 诊断

将两组 full-data 结果纳入 token diagnostics 后，行为证据的结构更加完整。表 3 已经给出七组设置的终点行为指标，图 6 进一步把关键 token 指标放在同一个视觉框架中。这里的重点不是简单确认 full-data 分数更高，而是观察更大数据预算是否也沿着同一类分布稳定化方向移动。结果表明，Base 与 Instruct 的 full-data 设置都没有破坏前文的解释框架：它们仍然表现为更短输出、更低 entropy、更少低置信 token 和更高 top-1 probability。




图 6: 七组主结果设置的聚合 token 行为指标对比。该图用于把 matched full-data 对照纳入与 one-shot、group-size 和奖励破坏设置相同的行为诊断框架。

Base 家族中, Base full-data 的 final score 达到 0.6105, 同时 response length 降到 536.0, 低置信 token 比例为 0.0308, token entropy 为 0.1718, 平均 top-1 probability 为 0.9378。与 Base n=8 相比, 它不仅分数更高, 而且输出更短、低置信 token 更少、平均 top-1 概率更高; 与 Base weak-reg. 相比, 它的 entropy 略高, 但分数明显更高。这说明 full-data 的优势并不是单纯来自更强的分布收缩, 而是来自更好的“收缩程度与正确性”平衡。

Instruct 家族中, Instruct full-data 的终点变化同样集中在稳定性指标上。它相对 Instruct n=8 将 response length 从 470.3 降到 452.7, 将低置信 token 比例从 0.0187 降到 0.0115, 将 token entropy 从 0.1322 降到 0.0837, 并将 top-1 probability 从 0.9634 提升到 0.9710。虽然分数增量只有 0.0145, 但 token 侧的变化说明 full-data 仍在高先验模型上产生了可测的分布收缩, 只是这种收缩对应的分数收益小于 Base 家族。

随机错误奖励设置在同一图中承担边界作用。它的 token entropy 上升到 11.5466, 低置信 token 比例达到 1.0000, top-1 probability 降到 0.0021, 说明错误奖励并不是让模型停留在初始状态, 而是把生成分布推向高度不稳定区域。把这一点与 full-data 的稳定化方向并列观察, 可以更清楚地区分三类现象: 有效奖励下的校准、数据预算扩大后的进

一步改善，以及错误奖励导致的分布崩解。

因此，七组聚合 token 诊断支持一个更强的结论：one-shot 与 full-data 的差异主要体现在同一稳定化方向上的程度差异，而不是完全不同的行为机制。Base 家族的 full-data 设置将 one-shot 的收益继续向上推进；Instruct 家族的 full-data 设置则在高起点附近继续做小幅收缩。这个结果使 full-data 对照不再只是“分数天花板”，而是成为验证行为解释是否可扩展到更大数据预算的重要证据。




图 7: Base 家族四组设置的验证响应长度变化，包含全尺度视图与局部放大视图。




图 8: Base 家族四组设置的验证 token entropy 变化，包含全尺度视图与局部放大视图。




图 9: Base 家族四组设置的低置信 token 比例变化, 包含全尺度视图与局部放大视图。




图 10: Base 家族四组设置的最终 EOS 概率变化, 包含全尺度视图与局部放大视图。




图 11: Base 家族四组设置的答案尾部置信度变化, 包含全尺度视图与局部放大视图。




图 12: Base 家族四组设置的平均 top-1 token 概率变化，包含全尺度视图与局部放大视图。

图 7 到图 12 使这种行为变化更加直观。每张图都采用“全尺度视图 + 正常奖励条件局部放大”的设计：全尺度视图保留随机错误奖励设置的异常方向，局部放大视图则避免异常线压缩正常条件之间的差异。尤其值得关注的是 response length、tail confidence、top-1 probability 与 EOS probability 的联动：随着训练进行，Base 家族普遍变得更短，也更倾向于在合适位置结束；与此同时，token entropy 与低置信 token 比例同步下降，而答案尾部置信度与平均 top-1 概率同步上升。这表明模型并非通过延长输出提升分数，而是通过更稳定的结束行为提升分数。对数学题这种最终答案明确、拖尾容易引入错误的任务而言，这一点尤其关键。




图 13: 非坍塌设置的行为细节图。该图聚焦四个非坍塌条件在 token entropy、low-confidence ratio、最终 EOS 概率与 top-1 probability 上的细微差异。

如果把随机错误奖励设置保留在同一坐标尺度里，许多成功条件之间的细节差异会被明显压缩。图 13 因而只保留四个非坍塌条件，用于比较成功设置之间的局部差异。该图显示：Base weak-reg. 在 entropy、top-1 probability 和 EOS probability 上都表现出更强的收缩，而 Base $n=1$ 则在这些指标上持续落后；Instruct $n=8$ 的曲线整体变化较小，更接近低熵高置信区域内的局部调整。

5.3 动态统计进一步强化了上述判断

训练与验证阶段的动态统计把前面的静态结果推进到了过程层面。与只看最终 checkpoint 不同，这些统计同时记录了训练期的 actor/entropy 和验证期的聚合 token 指标，因此能更直接地区分“真正变得更稳定的策略”和“仅在终点分数上略占优势的策略”。表 4 汇总了五组诊断设置从起点到终点的核心变化。

表 4: 训练与验证动态统计摘要 (起点 → 终点)

设置	actor 熵	验证熵	低置信	长度	top-1
Base n=8	0.346→0.116	0.660→0.202	0.115→0.037	812.5→603.1	0.854→0.932
Base n=1	0.641→0.085	0.532→0.317	0.095→0.051	762.8→580.4	0.873→0.921
Base weak-reg.	0.346→0.091	0.660→0.156	0.115→0.030	812.5→578.6	0.854→0.944
Base random-reward	0.376→11.594	0.633→11.547	0.110→1.000	762.8→1192.4	0.856→0.002
Instruct n=8	0.118→0.062	0.111→0.156	0.017→0.022	473.2→470.3	0.964→0.961

注：起点取第一个有值的训练或验证检查点，终点取最终验证检查点。验证 token 指标来自聚合 token diagnostics，每个检查点分析 64 个样本；五组诊断设置的覆盖率均约为 1.6%。




图 14: 五组诊断设置训练期 actor/entropy 变化，包含全尺度视图与局部放大视图。




图 15: 相同评估口径下, Base $n=8$ 与 Base $n=1$ 的六项动态对比。

这张表最直接地展示了 Base 与 Instruct 的分化。以 Base $n=8$ 为例, actor/entropy 从 0.346 降到 0.116, 验证 token entropy 从 0.675 降到 0.184, 低置信 token 比例从 0.116 降到 0.032, 聚合 top-1 概率从 0.851 升到 0.935, 验证响应长度则从 812.5 缩短到 603.1。弱正则化设置的收缩更强: 对应的最终 actor/entropy 进一步降到 0.091, 验证 token entropy 降到 0.156, top-1 概率升到 0.944。与之相对, Base random-reward 并未出现任何“轻微变差但仍有学习”的形态, 而是沿着完全相反的方向发展: actor/entropy 从 0.376 升到 11.594, 验证 token entropy 从 0.633 升到 11.547, 低置信 token 比例升到 1.000, top-1 概率坍缩到 0.002, 验证响应长度则暴涨到 1192.4。也就是说, Base 家族在正常奖励条件下的收益并不只是最终 reward 提高, 而是伴随着训练熵下降、验证熵下降、低置信 token 减少、top-1 概率升高与长度缩短的一整套同步变化; 一旦奖励信号被系统

性破坏，这整套变化会整体反向。

Base $n=1$ 进一步细化了 group size 的作用。该设置在 step 0 为 0.363，最终为 0.547，最佳检查点为 174、best score 为 0.559。在与 Base $n=8$ 完全一致的验证口径下，把训练 group size 从 8 降到 1 后，模型依然获得了显著收益，但 final score 低了约 0.026，best score 也低了约 0.016。与此同时，它的最终 token entropy 为 0.317，明显高于 Base $n=8$ 的 0.202 与 Base weak-reg. 的 0.156；低置信 token 比例为 0.051，也高于对应的 0.037 和 0.030；平均 top-1 概率则只有 0.921，低于 $n=8$ 的 0.932。图 15 进一步表明，这种差异不是单个 final checkpoint 的偶然波动，而是贯穿 score、entropy、length 与 top-1 probability 的整体形态差异。因此，把 group size 降到 1 不会阻止学习，但会削弱分布收缩与稳定闭合的质量。

Instruct 家族则呈现出另一种模式。Instruct $n=8$ 的 actor/entropy 只从 0.118 降到 0.062，验证长度几乎不变，top-1 概率也基本维持在 0.96 附近。这更接近局部调整，而不是结构性重整。在高先验模型上，当前 one-shot 级别的强化学习更多是在已有稳定分布附近进行细节调整，而不是像 Base 家族那样触发一次明显的分布重排。

5.4 弱约束版本的启示

Base weak-reg. 的 final score 与标准设置非常接近，但它的最终 entropy 更低、top-1 概率更高、响应也更短。这说明关闭 KL 和 entropy 约束后，模型并未立即失稳，而是朝着更强的分布收缩方向前进。这里需要谨慎：更强的收缩既可能意味着“更快收敛到较优解法”，也可能意味着“更容易过拟合或更依赖少量样本偏差”。当前证据只能确认它没有显著损伤最终准确率，但不能据此得出“约束项可有可无”的结论。

弱正则化设置的价值不在于证明约束无用，而在于表明：在极低样本强化学习里，最终分数并不足以代表训练过程的健康程度。后续分析可进一步关注检查点级波动和 representative failure case。

5.5 Instruct 模型主要是局部微调

Instruct $n=8$ 的最终行为指标呈现出另一种图景。它的 response length 本来就较短，tail confidence 本来就很高，low-confidence token ratio 也处于较低水平。训练后虽然仍然有一定变化，但幅度远小于 Base 模型。例如，它的 entropy 只是在低位小幅波动，EOS probability 始终接近 0.99。这说明 Instruct 模型的主要变化不是从高不确定性状态走向有序，而是在已有稳定分布上进行细节调整。

这类结果对研究假设具有关键意义。它说明同样的 1-shot GRPO 并不会以同样方式作用于所有模型。对于先验较弱的 Base 模型，它更接近校准机制；对于先验较强的 Instruct 模型，它更接近局部调整机制。

5.6 Token 级补充证据

5.6.1 补充材料的口径与边界

本文还纳入了一份 token 级诊断分析。它并不覆盖全部主结果设置，而是聚焦于固定题目上的完整轨迹子集。结合当前配置，更准确的理解应当是：每个检查点、每个设置最多有 64 个样本参与 token diagnostics 统计，但只有 8 条样本保留完整 token 轨迹，而且每条记录只保留前约 96 个 token。因此，这部分材料更适合作为“机制补充证据”，而不宜被直接外推为“对全部 500 题均成立的统计结论”。

尽管覆盖范围有限，这批 token 轨迹仍然具有较高价值。原因在于，它确实保留了 token 位置级的 logprob、entropy、top1_prob 和 top-k mass 等信息，可以更直接地检验“训练是否在早期 token 组织上做了校正”。需要同时指出的是，本文还额外拥有七组主结果设置共享的聚合 token 摘要曲线，因此 token 证据已经分成两层：一层是覆盖七组设置的 64-sample 聚合统计，用于支持整体方向和 matched full-data 对照；另一层是固定题目的完整轨迹，用于展示局部机制。

5.6.2 直接观察：Base 变化大，Instruct 变化小

图 16 与图 17 给出了固定题目上的 token 级可视化结果。Instruct 系列在 step 0 就已经具备较高的 token confidence 和较低的 entropy，训练后变化不大；Base 系列则表现出更明显的轨迹收缩和前缀稳定化。尤其在 Base-Full 与 Base-OneShot 的对比中，训练后期的 entropy 降幅和 top-1 概率增幅都清晰可见。




图 16: 固定题目在不同检查点上的保留轨迹。该图直观展示了训练后前缀组织与终止行为的变化。




图 17: 固定题目的 token 级熵、概率与长度等指标随检查点的变化。该图更适合支持“训练改变了早期 token 组织方式”的解释。

表 5 与表 6 进一步给出该固定题目的数字证据。首先，在 final checkpoint 上，Base-Full 的平均 entropy 为 0.2036，而 Instruct-Full 仅为 0.0778；对应的 top-1 概率分别为 0.9246 和 0.9705。其次，从 step 0 到 final，Base-Full 与 Base-OneShot 的 logprob 增量和 entropy 下降幅度都远大于 Instruct 系列。这说明 Base 模型的训练变化确实更剧烈，也更符合一次显著行为校准的特征。图 16 与图 17 提供了与这些数值一致的可视化证据。

表 5: 固定题目在 final checkpoint 上的 token 级摘要

设置	correct?	traced tokens	entropy	top1 prob	top5 mass
Base-Full	correct	768	0.2036	0.9246	0.9970
Base-OneShot	correct	672	0.2005	0.9248	0.9970
Base-OneShot	wrong	96	0.2435	0.9056	0.9977
Instruct-Full	correct	768	0.0778	0.9705	0.9998
Instruct-OneShot	correct	768	0.1119	0.9580	0.9996

表 6: 固定题目从 step 0 到 final 的 token 级变化量

设置	$\Delta \logprob$	$\Delta \text{entropy}$	$\Delta \text{top1 prob}$
Base-Full	+0.3673	-0.3908	+0.0762
Base-OneShot	+0.3849	-0.3885	+0.0740
Instruct-Full	+0.0744	-0.0760	+0.0268
Instruct-OneShot	+0.0435	-0.0419	+0.0143

5.6.3 与主结果结论的衔接

这些 token 图并不替代主结果，而是增强主结果的解释力。宏观统计已经显示：Base 模型收益大，Instruct 模型收益小；token 级补充材料进一步表明，这种差异体现在前缀组织方式、分布收缩和正确结束行为上。二者共同形成一条较完整的证据链。

5.6.4 前缀分布的重新组织

如果将注意力集中到最终答案附近，前面的结论已经足以说明训练后分布更加稳定；但若进一步考察输出前缀的位置级分布，则能够看到更具体的变化方向。图 18 展示了 final checkpoint 上不同设置在前缀 token 区域的曲线差异。它的价值在于把“最终答对”拆解为“是否从输出前缀就沿着更稳定的轨道展开”。对于 Base 家族而言，这一点尤其重要，因为它们的改进并不是只发生在最后一两个答案 token 上，而是从更早的前缀阶段就开始体现为更低的熵和更集中的 top-1 概率。

图 18 与前面的动态聚合曲线能够相互印证。聚合统计表明，Base 家族在检查点级统计上持续收缩；前缀图进一步说明，这种收缩并不是平均到所有位置后才显现，而是在输出早期就已经发生。对于数学推理任务，这意味着模型更快地进入正确的结构化推理轨道，而不是先经过一段模糊、犹豫的路径，再在答案末端临时纠正。




图 18: final checkpoint 上不同设置在前缀 token 区域的曲线差异。该图用于说明训练后前缀组织本身发生了系统变化，而不仅仅是末尾答案更稳定。

5.6.5 从初始到终点的局部 token 分布收缩

图 19 把关注点放到训练前后差值本身。相比只看 final checkpoint，该图更适合刻画模型变化是整体轻微改善，还是集中在若干关键位置的明显分布重排。Base 条件的变化幅度远大于 Instruct 条件，尤其是在早期和中段 token 区域，logprob 上升与 entropy 下降同时出现。这与前文关于 Base 快速校准、Instruct 局部调整的解释一致。

$n=1$ 设置的结果也可以从这类图里得到补充。虽然完整轨迹图本身不是为该设置单独生成的，但它所呈现的变化模式与聚合结果相匹配：训练能够让 Base 模型在 token 级分布上变得更稳，而当 group size 缩小后，这种分布清理仍然发生，却不如 $n=8$ 那样充分。也正因为如此，正文里关于 group-relative signal 的判断并不是仅仅依赖一个汇总分数，而是有来自局部 token 变化形态的间接支撑。




图 19: 从初始到终点的 token 级变化。

5.6.6 按正确性分组的分布分离

为检验分布收缩是否真正对应更高的任务成功率，本文在保留 token-diagnostics 摘要的 validation records 上按响应正确性分组，比较 mean token entropy 与 mean top-1 probability。图 20 汇总了六个非坍塌设置在 final checkpoint 的 64-sample 摘要统计，并进一步跟踪 Base 与 Instruct 家族中 one-shot/full-data matched pairs 的正确性分组差距。结论方向高度一致：正确响应系统性位于更“收缩”的一侧，即 entropy 更低、top-1 probability 更高。

从 final checkpoint 的跨设置比较看，这种分离在六个非坍塌条件下均可观测。具体而言，Base $n=8$ 的正确组与错误组 mean token entropy 分别为 0.165 和 0.237，Base full-data 为 0.162 和 0.209，Base $n=1$ 为 0.159 和 0.570，Base weak-reg. 为 0.152 和 0.172，Instruct $n=8$ 为 0.087 和 0.499，Instruct full-data 为 0.074 和 0.163；对应的 mean top-1 probability 分别为 0.939/0.925、0.940/0.929、0.941/0.878、0.945/0.940、0.968/0.925 和 0.972/0.967。尽管不同条件下的分离幅度并不相同，但方向完全一致。这

说明正文中反复出现的 entropy 收缩和置信度集中并非与任务无关的表面现象，而是与最终解题成功率稳定相关。

训练过程中的分组统计进一步表明，这一关系并非只出现在终点 checkpoint。图 20 下排把 matched one-shot/full-data pairs 的分组差距画成曲线：entropy gap 定义为错误组减正确组，top-1 gap 定义为正确组减错误组。对于 Base 家族，Base n=8 与 Base full-data 在 step 0 共享相同差距，final checkpoint 的 entropy gap 分别为 0.072 和 0.047，top-1 gap 分别为 0.0149 和 0.0105；对于 Instruct 家族，Instruct n=8 与 Instruct full-data 的 final entropy gap 分别为 0.412 和 0.089，top-1 gap 分别为 0.0429 和 0.0047。换言之，正确性分组下的分布分离贯穿 one-shot 与 full-data 对照，而不是某个局部 traced subset 的偶然现象。随机错误奖励设置由于 final checkpoint 已无正确响应，因此未纳入该图。

本节从两个层次回答机制问题：宏观行为指标展示整体稳定化方向，token 级轨迹则说明这种变化也能在生成内部结构中观察到。因此，这部分证据并不是额外堆叠的图表，而是在不同粒度上支撑同一个“快速行为校准”解释。




图 20: 按正确性分组的 token 分布统计。上排比较六个非坍塌设置在 final checkpoint 的正确组与错误组；下排展示 Base 与 Instruct 家族中 one-shot/full-data matched pairs 的正确性分组差距随训练变化。

表 7: final checkpoint 上按正确性分组的 token 分布摘要

设置	正确/错误样本	熵 C/W	top-1 C/W	EOS C/W	tail C/W
Base n=8	47/17	0.165/0.237	0.939/0.925	0.002/0.001	0.957/0.866
Base full-data	51/13	0.162/0.209	0.940/0.929	0.003/0.002	0.944/0.885
Base n=1	45/19	0.159/0.570	0.941/0.878	0.003/0.011	0.949/0.785
Base weak-reg.	51/13	0.152/0.172	0.945/0.940	0.002/0.001	0.958/0.889
Instruct n=8	57/7	0.087/0.499	0.968/0.925	0.002/0.002	0.973/0.830
Instruct full-data	57/7	0.074/0.163	0.972/0.967	0.002/0.002	0.978/0.877

表 7 以数字形式补充图 20。其中 C/W 分别表示正确组与错误组。可以看到，六个非坍塌设置都满足正确组 entropy 低于错误组、正确组 top-1 probability 高于错误组这一方向性关系。这个结果很重要，因为它把“分布收缩”从全局均值现象推进到了按正确性分组的内部比较：模型并非只是整体上变得更尖锐，而是正确响应更集中地落在低熵、高 top-1 的区域。

表 8: matched one-shot/full-data pairs 的正确性分组差距

设置	step 0 熵差	final 熵差	step 0 top-1 差	final top-1 差
Base n=8	0.603	0.072	0.0833	0.0149
Base full-data	0.603	0.047	0.0833	0.0105
Instruct n=8	0.095	0.412	0.0021	0.0429
Instruct full-data	0.095	0.089	0.0021	0.0047

表 8 则强调训练过程中的 matched 对照。熵差定义为错误组减正确组，top-1 差定义为正确组减错误组，因此正值表示正确响应更低熵、更高置信。Base 家族中，one-shot 与 full-data 在初始 checkpoint 上共享完全相同的分组差距，说明二者起点可比；训练结束后，full-data 的错误组相对不再那么分散，熵差从 0.603 收窄到 0.047，而 one-shot 收窄到 0.072。Instruct 家族也共享相同起点，但 Instruct n=8 的 final 熵差更大，主要是因为错误样本数量少且错误响应更分散；Instruct full-data 的错误组则更接近正确组，体现出高先验模型在 full-data 下更一致的输出形态。

这些分组统计使 token 级论证更接近正式论文中的机制证据。它们既不把少数完整 trace 过度外推为全验证集结论，也没有只停留在全局均值。相反，它们在 64-sample 聚合 token diagnostics 的范围内，直接检验了正确性与局部分布形态之间的对应关系。结合主分数、终点行为指标和 fixed-prompt trace，可以得到更稳健的解释：有效奖励训练提升分数的同时，也把成功响应推向更低熵、更高置信的生成区域；full-data 进一步提高上限，但总体仍遵循同一类校准机制。

5.7 保存 checkpoint 的全量 token 离线诊断

为弥补训练期 validation diagnostics 只保留前缀 token 的限制，本文对保存 checkpoint 进行离线重评估。该流程从保存的 actor checkpoint 恢复模型，在 MATH500 vali-

dation set 上重新生成响应，并对每条响应的全部生成 token 计算 logprob、entropy、EOS probability、top-1 probability 与 top-k mass。与原训练日志中的前缀诊断不同，本节覆盖完整响应长度，因此更适合作为 checkpoint 级行为分析。

本次离线评估覆盖 step 0 到 step 180，每个 step 包含 32 道题、128 条采样响应。最终 checkpoint 的平均 score 为 0.6172，最佳 checkpoint 为 step 60，best score 为 0.6172。从行为指标看，最终平均 response length 为 662.9，token entropy 为 0.2188，低置信 token 比例为 0.0398，平均 top-1 probability 为 0.9256。

表 9: 保存 checkpoint 的离线全量 token 评估摘要

Step	score	length	entropy	low-conf.	top-1	tail conf.
0	0.3047	812.1	0.6982	0.1254	0.8385	0.7755
60	0.6172	609.9	0.2394	0.0452	0.9184	0.9220
120	0.5859	608.9	0.2710	0.0492	0.9149	0.9066
180	0.6172	662.9	0.2188	0.0398	0.9256	0.9066

更关键的是，这组结果不仅重复了“分数提高”这个结论，而是把分数变化拆成了可解释的生成行为变化。step 0 到 step 60 是最明显的相变区间：score 从 0.3047 升到 0.6172，平均 response length 从 812.1 降到 609.9，token entropy 从 0.6982 降到 0.2394，低置信 token 比例从 0.1254 降到 0.0452，top-1 probability 从 0.8385 升到 0.9184。这说明保存 checkpoint 审计中观察到的主要收益不是来自更长的搜索，而是来自更短、更集中、更少低置信 token 的输出轨迹。

step 60、120 和 180 之间的差异也值得保留，而不是只报告最终数值。step 60 与 step 180 的 score 同为 0.6172，但二者的行为形态不同：step 180 的 entropy 更低、top-1 probability 更高、低置信 token 比例更低，却比 step 60 平均长约 53 个 token，tail confidence 也从 0.9220 降到 0.9066。step 120 则在长度几乎不变的情况下 score 降到 0.5859，同时 entropy 和低置信比例略有回升。这个对比表明，checkpoint 质量不能只由“更短”或“更尖锐”单个指标决定；更合理的解释是，训练在分数、长度、置信度和尾部闭合之间移动，而较好 checkpoint 位于这些指标的平衡区间。

EOS token 的变化需要单独解释。这里的 EOS 指标表示在每个生成位置上模型分布分给 EOS token 的概率，以及 EOS 是否进入高概率或 top-1 区域，而不是简单的“样本是否以 EOS 结束”。表 10 将数值统一乘以 10^4 以便阅读。整体上，训练并没有把模型推向随处高 EOS 概率的状态：mean EOS probability 从 step 0 的 2.613 降到 step 60 的 0.827，并在 step 120 进一步降到 0.098；step 180 回升到 0.806，但仍明显低于初始水平。final-position EOS probability 也呈现类似的非单调变化，step 60 和 step 120 显著低于 step 0，step 180 末端有所回升但仍低于初始。这个结果说明，分数提升并不是通过更强的提前停止完成的；更合理的解读是，训练先压低不必要的 EOS 压力，让模型更稳定地产生解题轨迹，而最终 checkpoint 在响应尾部重新出现一定的闭合倾向。

表 10: 全量 token 离线评估中的 EOS 概率变化 (数值均为原始比例 $\times 10^4$)

Step	mean EOS	final EOS	EOS > 0.1 ratio	EOS top-1 ratio
0	2.613	8.906	2.547	2.399
60	0.827	0.408	1.488	0.548
120	0.098	0.230	0.069	0.108
180	0.806	2.586	2.121	0.961

按正确性分组的全量 token 统计进一步加强了这一点。在 final checkpoint 上, 按 token 加权后, 正确响应的 entropy 为 0.1850, 错误响应为 0.2619; 正确响应的 top-1 probability 为 0.9345, 错误响应为 0.9156。样本级均值给出了更直观的对照。表 11 显示, 在每个 checkpoint 上, 正确组都显著短于错误组, 并且具有更低 entropy、更低低置信 token 比例、更高 tail confidence 与更高 top-1 probability。最终 checkpoint 上, 正确样本平均长度为 476.5, 而错误样本为 963.4; 正确样本 entropy 为 0.1765, 错误样本为 0.2871; 正确样本 low-confidence ratio 为 0.0301, 错误样本为 0.0555。这说明完整响应级别的正确样本不仅更自信, 而且更短、更稳定、更接近有效闭合。

表 11: 全量 token 离线评估中的正确/错误样本级分组统计

Step	group	n	length	entropy	low-conf.	tail conf.	top-1
0	correct	39	482.4	0.3282	0.0619	0.8875	0.8978
0	wrong	89	956.5	0.8603	0.1533	0.7264	0.8125
60	correct	79	482.5	0.2231	0.0412	0.9286	0.9229
60	wrong	49	815.4	0.2657	0.0517	0.9114	0.9112
120	correct	75	473.1	0.2126	0.0388	0.9298	0.9268
120	wrong	53	801.2	0.3537	0.0639	0.8737	0.8980
180	correct	79	476.5	0.1765	0.0301	0.9381	0.9362
180	wrong	49	963.4	0.2871	0.0555	0.8559	0.9084

这些正确/错误分组结果与正文中七组设置的聚合 token diagnostics 一致, 因此全量离线诊断不是孤立的可视化材料, 而是把“正确性与分布稳定化相关”这个机制结论从保留前缀扩展到了完整生成轨迹。它也进一步限定了 EOS 指标的解释: 有效训练并不等于简单提高 EOS 概率, 而是在不制造提前停止压力的情况下, 使正确响应更短、更低熵、更高置信, 并在尾部形成更稳定的闭合。

图 21 进一步把这种变化落实到可读的推理文本上。该图追踪同一道 held-out MATH500 题在 step 0、60、120 和 180 的生成结果: 图中直接显示模型生成的单词或公式片段, 背景颜色表示对应 token 的 entropy。可以看到, step 0 的推理文本中高熵区域更多, 推理路径也更不稳定; 最终 checkpoint 的可见推理片段更结构化、更低熵, 并且给出正确答案。由于完整响应较长, 图中只展示可读片段, 因此它应被理解为定性轨迹证据, 而不是完整输出转录。

Token entropy over generated reasoning: MATH500 #18, sample 0

step 0 | score=0.000 | mean entropy=4.657 | length=863

```python

# We are given that  $AB = BC$  and that segment  $BC$  is collinear with the segment through  $A$ .

#  $AB$  and  $BC$  form a straight line, and therefore angle  $B$  is 2 degrees more than the concurrency point because it is supplementary angles.

# angle  $AB = x$  degrees and angle  $BCA = 124^\circ$ .

# Since  $AB = BC$ , angle  $BAC$  is equal to angle  $ACB$ , let it be  $y$ .

... truncated for display

step 60 | score=0.000 | mean entropy=0.233 | length=608

Given:

1.  $\overline{BC}$  is parallel to the segment through  $A$ .

2.  $AB = BC$ .

3.  $\angle ABR = 124^\circ$ .

We need to find the value of  $\angle ABC$ , which is the measure of  $\angle ABC$ .

Steps:

1. Since  $\overline{BC}$  is parallel to the segment through  $A$ , the angle  $\angle ABR$

... truncated for display

step 120 | score=0.000 | mean entropy=0.219 | length=1039

First, let's analyze the given problem and the relationships between the angles.

1. We are given that  $\overline{BC}$  is parallel to the segment through  $A$ .

2. Since  $AB = BC$ , triangle  $ABC$  is isosceles, with  $\angle BAC = \angle BCA$ .

3. We are also given that the angle at  $A$  is  $124^\circ$ . Since  $\overline{BC}$  is parallel to the segment through  $A$ , the angle at  $A$  is equal to the angle at  $C$  (alternate interior angles). Therefore,  $\angle BAC = 124^\circ$  and  $\angle BCA = 124^\circ$ .

4. The sum of the angles in a triangle is  $180^\circ$ . So, we can write the equation for

... truncated for display

step 180 | score=1.000 | mean entropy=0.259 | length=485

Given:

-  $\overline{BC}$  is parallel to the segment through  $A$ .

-  $AB = BC$ .

- We need to find the number of degrees represented by  $\angle ABC$ .

Since  $\overline{BC}$  is parallel to the segment through  $A$ , we can use the properties of parallel lines and transversals. The angle  $\angle ABC$  and the given angle  $124^\circ$  are corresponding angles, meaning they are equal.

... truncated for display

low entropy high entropy

图 21: 代表性样本的词级 entropy 轨迹图。图中每个单词或公式片段均来自模型生成文本, 背景越暖表示该位置 token entropy 越高。




图 22: 保存 checkpoint 的离线全量 token 评估: validation score 与响应长度随 checkpoint 变化。




图 23: 保存 checkpoint 的全量 token 置信度与 entropy 指标。该图使用完整响应 token, 而非训练期保留的前缀子集。




图 24: 保存 checkpoint 的 EOS 行为、top-1 probability 与 top-k mass。EOS probability 衡量每个生成位置上模型分布分给 EOS token 的概率。




图 25: 最终 checkpoint 上按响应位置分桶的全量 token 指标。横轴为响应内相对位置 decile。




图 26: 最终 checkpoint 上按正确性分组的全量 token 指标。

这组结果应作为现有 token 级补充证据的加强版来解读：训练期记录能展示早期 token 的局部轨迹，而离线重评估可以覆盖更大的 held-out 子集与完整响应长度。二者方向一致，说明“分布稳定化”并非只发生在少量固定题目的前缀区域，而是能在完整生成轨迹上观察到。它同时也给出一个更细的边界：full-data checkpoint 的收益确实伴随更强校准，但最终 checkpoint 不一定在所有行为指标上同时最优，因此后续分析仍应同时报告 best checkpoint、final checkpoint 和关键 token 行为指标。

## 6 小组规模与奖励信号分析

### 6.1 $n=1$ 小组规模消融的解释边界

Base  $n=1$  在与 Base  $n=8$  相同的验证协议下表现出明确收益。其分数从 0.3630 提升到 0.5470, best score 为 0.5590, 说明将 group size 降到 1 仍可产生实质改进; 但在相同验证设置下, 它稳定落后于  $n=8$  的 0.5733 / 0.5753。这意味着当前证据并不支持“group size 无关紧要”的解释, 而更支持如下判断: group-relative signal 并非收益存在的必要条件, 但对于获得更高、更稳定的最终收敛结果具有重要作用。

这一结论仍需谨慎解释。 $n=1$  与  $n=8$  的对比目前仍基于单次训练结果, 因此更适合作为支持性证据, 而非多 seed 意义下的最终结论。

### 6.2 随机错误奖励设置的解释意义

随机错误奖励设置的核心目的, 是检验正常奖励条件下的收益是否真正依赖于有意义的训练信号。如果把奖励系统性破坏后, 模型仍能复现正常奖励收益, 那么“训练确实利用了有效监督结构”这一解释就会被显著削弱; 反之, 如果破坏性奖励导致性能和分布同时坍塌, 那么正常奖励条件下的改善就更可以被解释为对真实训练信号的响应。

表 12: 随机错误奖励设置的终点行为

| 指标                         | 数值      |
|----------------------------|---------|
| final score                | 0.00025 |
| final response length      | 1192.4  |
| final tail confidence      | 0.0001  |
| final low-confidence ratio | 1.0000  |
| final token entropy        | 11.5466 |
| final EOS probability      | 0.0009  |
| final top-1 probability    | 0.0021  |

Base random-reward 与正常奖励设置呈现出截然不同的结果。它从 0.3630 起步, 却在训练过程中迅速坍塌到 0.00025; 与此同时, 响应长度从 762.8 增长到 1192.4, low-confidence token 比例升到 1.000, token entropy 升到 11.5466, EOS 结束概率降到 0.0009, 平均 top-1 概率也几乎退化为均匀分布水平。表 12 汇总了这种终点崩解状态。就论文论证而言, 这是一条关键证据: 当奖励信号被系统性破坏后, 模型不会复现正常奖励条件下的收益, 而是失去稳定生成能力。需要强调的是, 该设置不是“无信号”消融, 而是主动注入随机错误奖励的更极端奖励破坏对照; 因此它能说明错误奖励会破坏收益, 但不能单独等价于“没有奖励信号”的情形。



## 7 训练动态与证据综合

### 7.1 收益的阶段分布

仅知道 final score 较高，还不足以说明训练过程是否健康。更有解释力的问题是收益的阶段来源：主要来自前期快速提升，还是来自后期缓慢累积。图 27 把七组主结果设置的主分数增量拆成三个阶段：0→36、36→96 和 96→180。这种拆法虽然是经验性的，但足够把“起步纠偏”“中段巩固”和“后期波动”区分开来。

Base 正常奖励设置的主要收益集中在前两个阶段，尤其是 0→36 的快速提升最为明显。这与本文强调的“快速校准”一致：模型先被迅速移出初始的高熵、长拖尾状态，然后在中段继续巩固正确轨道；最后阶段的收益更有限，主要体现为小范围高位波动。相比之下，Instruct 设置几乎没有可观的阶段增益，说明其训练并不是一次明显的结构性重排，而更接近高位附近的局部调整。随机错误奖励设置则沿完全相反方向演化，其坍塌主要发生在训练前中期。




图 27：七组主结果设置主分数增量的阶段性分解。

### 7.2 最佳 checkpoint 与最终 checkpoint 的偏离

在低数据预算强化学习里，最佳点和终点往往并不相同。图 28 将这个现象拆成两个量同时展示：一是 best score - final score 的差值，二是最佳验证检查点所在的位置。这个图的意义在于，它把前文分散在各处的观察集中起来：虽然多个设置最终都停在 step 180，但真正最优的 checkpoint 常常更早出现。

这个现象对结果分析具有重要意义。它说明当前训练过程更接近“快速进入高位区间后在后期轻微振荡”，而不是单调改进过程。对 Base 模型而言，这意味着如果任务目标是获得最佳验证性能，那么早停或 checkpoint selection 都值得纳入训练策略讨论；对 Instruct 模型而言，则意味着它本来就缺乏大幅收益空间，后期训练更容易表现为噪声而不是确定性的改进。




图 28: 七组主结果设置的最佳 checkpoint 与最终 checkpoint 对比。

### 7.3 终点行为排序的补充证据

图 29 对七组主结果设置的若干终点行为指标做了统一排序, 包括最终 token entropy、低置信 token 比例、top-1 probability 和响应长度。相比逐个在正文中报数字, 这种图更容易看出整体格局。它表明 Base 家族内部虽然都能获得较高收益, 但不同设置的“收敛风格”并不完全相同: Base full-data 在长度和低置信比例上进一步改善, 弱正则化设置表现出更强的收缩, 标准 n=8 设置更为稳健, n=1 则在最终熵与低置信比例上都落后于 n=8, 而随机错误奖励设置则远离所有正常收敛区间。Instruct 家族中, full-data 进一步降低 entropy 和低置信比例, 但分数增量仍明显小于 Base 家族。

该排序图说明论文分析不能只依赖单一 reward。若只看 final score, 弱正则化设置与标准 n=8 设置十分接近; 但终点 token 指标并排观察后可以发现, 它们在收缩强度、闭合方式和输出长度上并不相同。与此同时, 随机错误奖励设置清楚展示了奖励被破坏后的崩解形态。这个对照说明, 主分数与行为分布的联合分析比单个汇总数字更具有解释力。




图 29: 七组主结果设置终点行为指标排序图。

## 7.4 多指标之间的耦合关系

### 7.4.1 收益提升与校准量的同步关系

正文已经分别讨论了主分数、行为指标和 token 补充材料。进一步需要检验的是，这些变化是否只是在方向上相同，还是在设置层面上也呈现同步耦合。图 30 将七组主结果设置的主分数增益，分别与四类动态量的变化幅度并排展示：训练期 actor entropy 的变化量、验证期 token entropy 的变化量、低置信 token 比例的变化量，以及验证响应长度的变化量。其中 actor entropy 受训练日志字段覆盖限制，full-data 两组主要通过验

证期聚合 token 指标进入该图。

该图将“快速校准”从一种合理解释进一步推进为更严格的经验模式。Base 正常奖励设置并不只是 reward 提升更大，它们同时也对应更大的 entropy 收缩、更大的低置信 token 减少，以及更明显的长度压缩。Instruct 设置则整体落在另一侧：分数提升小，动态收缩也小。更关键的是，Base random-reward 落在图中的完全反方向，表现为 reward 下降、熵上升、低置信比例上升以及长度拉长。这种设置层面的同步关系表明，“收益”和“分布稳定化”并不是彼此独立的两条观察，而是在同一批结果中共同出现。




图 30: 七组主结果设置的主分数增益与四类关键动态量变化幅度的耦合关系。训练期 actor entropy 面板按日志可用性显示设置点。

### 7.4.2 终点性能与终点稳定性的共同前沿

另一个重要维度是终点分数与终点分布稳定性之间的关系。图 31 将最终验证分数分别与最终 token entropy、最终低置信 token 比例放在同一张图中。七组设置点使这种前沿式展示更有价值，因为它把“效果更好”和“分布更稳”压缩到了同一个坐标系里，并允许直接观察 one-shot 与 full-data 的终点位置差异。

Base 家族内部基本呈现出清晰趋势：最终分数更高的设置，通常也对应更低的 entropy 与更低低置信 token 比例。Base n=1 在这两个坐标上都明显落后于 Base n=8，因此它的劣势不是只体现在某一条 reward 曲线上，而是体现在终点分布质量本身。Instruct 家族则落在另一块区域：它们整体分数更高，但内部变化幅度有限，说明其收益空间本来就不大。这种分区形态进一步表明，模型先验强弱与分布稳定化程度共同决定了最终性能所处的位置。




图 31: 最终验证分数与最终稳定性指标的联合前沿图。

### 7.4.3 跨指标图的证据作用

如果将这些图与前文结合起来考察，全文的证据组织可以归纳为更严密的三层结构。第一层是主分数与 best checkpoint，说明训练确实带来了可观收益；第二层是长度、entropy、top-1 probability、EOS 和 low-confidence ratio 的动态变化，说明收益伴随可解释的行为重排；第三层就是本节的耦合图 and 前沿图，它们把不同指标重新放回设置层面上联合观察，从而证明这些现象在设置层面也是同步的。由此，本节回答训练动态与证据

综合问题：收益主要在前中期形成，后期进入高位波动区间，并且这种收益与分布稳定化在设置层面保持同步。

## 8 讨论

### 8.1 主要支持证据

本文的主要支持证据不是单个分数，而是一组相互支撑的现象：Base 模型的正确率显著提升，响应长度缩短，尾部置信度提升，低置信 token 比例下降，token entropy 下降，EOS 概率上升，token 级补充材料中也能看到前缀组织和分布收缩的明显改善。这些现象共同指向同一个解释：1-shot GRPO 对 Base 数学推理模型的主要作用，是把已有能力更快地校准到更稳定的输出轨道上。

### 8.2 当前限制

当前限制也较为明确。第一， $n=1$  与  $n=8$  的同口径比较仍是单次训练结果，尚未形成多 seed 稳健性证据。第二，随机错误奖励设置目前只覆盖 Base 家族，尚缺与之匹配的 Instruct 结果。第三，当前诊断支持“快速校准”解释，但还不能完全分离校准与跨题型、跨难度的知识获得；更直接的后续测试应按题目难度或知识领域分层，检验收益是较均匀地出现，还是集中在特定知识区域。第四，full-data 结果已经纳入主分数、终点行为指标和正确性分组 token 摘要，但训练期 actor entropy 与固定题目完整轨迹仍未形成七组完全对称覆盖。第五，token diagnostics 虽然覆盖到每个检查点的 64 个诊断样本，但完整 token 轨迹只对其中 8 条样本落盘，因此宏观结论仍应主要建立在逐样本验证均值上，而不是依赖少量固定题目的 token 轨迹。

### 8.3 外推边界

这些限制并不改变主结论，但限定了它的外推范围。当前证据足以支持“Base 模型在 1-shot GRPO 下出现显著收益并伴随行为分布稳定化”，但不宜进一步声称 group size 差异已经具备多 seed 级别的稳健性，也不宜把 Base 家族中的随机错误奖励结论直接外推到 Instruct 家族。类似地，full-data 已经能够与 one-shot 进行同口径主结果和聚合 token 指标比较，但完整轨迹与训练期 actor 指标仍应被视为覆盖范围较窄的补充证据。

### 8.4 当前证据链汇总

为了避免正文在最后阶段重新退化成孤立的汇总数字，表 13 对当前最重要的判断做了集中汇总。它的作用不是重复前文，而是把“结论判断、主要证据和仍需保留的边界”放在同一张图景里，方便读者在结尾快速把握证据链。



表 13: 当前关键结论的证据状态汇总

| 结论判断                                | 主要证据                                                                                                                                      | 仍需保留的边界                                     |
|-------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------|
| 1-shot GRPO 对 Base 数学推理模型有效         | 主分数曲线、Base 正常奖励设置约 0.20 的绝对提升、行为指标同步改善                                                                                                    | 仍需更多 seed 检验其跨随机初始化和采样噪声的稳定性                |
| 1-shot 低数据收益低于 matched full-data 结果 | Base/Instruct full-data 结果均高于对应 one-shot baseline, Base final 差距约 0.0373, Instruct final 差距约 0.0145; 聚合 token 指标与正确性分组统计也已纳入 full-data 对照 | 训练期 actor 指标和完整 token 轨迹仍不是七组完全对称覆盖         |
| 收益更符合快速校准而非知识注入                     | response length 缩短、entropy 下降、low-conf 降低、top-1 与 EOS 上升、固定题目轨迹证据支持                                                                       | 当前诊断尚不能完全区分校准与跨题型、跨难度知识获得                   |
| group-relative signal 对最佳结果有帮助      | n=1 在 matched validation protocol 下稳定落后于 n=8                                                                                              | 目前仍是单次训练结果, 尚缺少 seed 复验                     |
| 奖励破坏会破坏训练收益与分布稳定化                   | Base random-reward 中 score 坍塌、entropy 爆炸、low-conf 饱和、EOS 与 top-1 置信度崩解                                                                    | 该设置属于极端错误信号对照, 不是纯无信号消融; 且当前仅在 Base 家族上完成验证 |

9 统一机制解释

9.1 从分数提升到分布稳定化

综合七组实验可以看到，本文的核心现象并不是某一条分数曲线单独上升，而是一组指标在同一方向上共同移动。对于 Base 家族，正常奖励设置下的 score 提升、输出缩短、entropy 降低、低置信 token 减少和 top-1 probability 上升同时出现；对于 Instruct 家族，起点本身已经更稳定，后续训练主要表现为幅度较小的局部收缩；对于随机错误奖励设置，几乎所有行为指标都朝相反方向发展。这种对称结构使“快速校准”成为比“单纯知识注入”更合适的解释。

如果训练主要是在单个样本中提取新的数学知识，那么更直接的预期是模型在与该样本相近的问题上获得收益，但并不必然伴随全局响应长度、EOS 行为和 token entropy 的系统变化。当前结果却显示，收益和分布变化高度耦合：模型不仅答对更多题，而且更少生成冗长、低置信和拖尾式的响应。换言之，训练似乎在改变模型如何使用已有推理能力，而不只是增加某个新的知识片段。

这一点在 Base 模型上最明显。Base n=8 与 Base weak-reg. 的 final score 接近，但它们的终点分布并不完全相同。弱正则化设置更强烈地压低 entropy 并提高 top-1 probability，而标准 n=8 设置的收缩更温和。这说明最终分数相近并不等价于机制完全相同。相反，两个设置可能达到类似正确率，却对应不同的置信度组织方式和不同的收敛风格。因此，本文反复把 score 与 token 指标并列，是为了避免把复杂的训练过程压缩成单个 reward 数字。

## 9.2 full-data 对照的解释位置

两组 full-data 实验使这种解释更稳固。它们不是外部参考，也不是单独的“更强 baseline”，而是在相同验证口径和训练日程下扩大数据预算的 matched 对照。Base 家族中，full-data 将 final score 从 one-shot 的 0.5733 推高到 0.6105，同时保持更短输出和更低低置信比例。Instruct 家族中，full-data 将 final score 从 0.6873 推高到 0.7018，并进一步降低 entropy 与低置信 token 比例。两类模型方向一致，但幅度不同。

这个结果对主结论有两层含义。第一，1-shot GRPO 的收益是真实而有意义的，因为它在极低数据预算下已经复现了 full-data 方向上的大部分行为变化。第二，1-shot 并没有达到同日程下的 full-data 上限，尤其是在 Base 家族中仍有明显差距。因此，更准确的表述不是“一个样本足以完全替代 full-data”，而是“一个样本已经足以触发与 full-data 同方向的校准过程，但数据预算扩大仍能提高最终上限”。

从 token 角度看，full-data 的价值同样不是只体现在分数上。Base full-data 的 response length、low-confidence ratio 和 top-1 probability 都优于 Base n=8，说明更多数据确实带来了更稳定的输出形态；Instruct full-data 相对 Instruct n=8 的改善幅度较小，但在 entropy 和低置信 token 上仍可观察到进一步收缩。这支持一个更细的解释：数据预算扩大主要提高了校准过程的充分性，而不是改变了校准过程的方向。

## 9.3 group size 与奖励结构的作用

Base n=1 的结果说明，group-relative signal 不是收益存在的绝对前提，但会影响收益质量。在相同验证口径下，n=1 仍然带来明显提升，说明单样本奖励本身已经包含可利用的优化信号；但它稳定低于 n=8，并且在 final entropy、low-confidence ratio 和 top-1 probability 上也更弱。这表明 group size 的作用不只是提高分数，而是帮助模型更充分地完成分布收缩。

从 GRPO 的机制看，这一点是合理的。较大的 rollout group 提供更多同题候选之间的相对比较，使优化过程能够更精细地区分“同样看似合理但置信度、闭合性和答案质量不同”的轨迹。当 group size 降为 1 时，训练仍能利用奖励方向，但失去了组内相对排序的部分信息。因此，n=1 的收益存在并不推翻 group-relative learning 的价值；相反，它表明奖励信号和组内比较可能是两种互补因素。

随机错误奖励设置则从另一个方向限定了解释边界。该设置不是“没有信号”，而是系统性注入错误信号。结果显示，模型并没有保持初始能力，也没有复现正常奖励设置下的收益，而是在分数和 token 分布上同步崩解。这说明训练流程本身不足以解释收益；如果奖励结构被破坏，同样的优化过程会把模型推向错误方向。也因此，本文把随机错误奖励定位为奖励完整性检验，而不是温和的无信号消融。

## 9.4 正确性分组证据的作用

正确性分组分析进一步连接了宏观分数与微观 token 分布。若仅观察全局均值，可能存在一种质疑：entropy 降低和 top-1 probability 上升只是训练副产品，并不一定与答题成功有关。按正确性分组后可以看到，正确响应在六个非坍塌设置中都具有更低 entropy 和更高 top-1 probability。这说明分布收缩不是与任务无关的表面变化，而是与最终正确性稳定相关。

同时，正确性分组也提醒我们不要过度简化“低 entropy = 好”的判断。随机错误奖励设置同样可能在某些局部位置表现出确定性，但整体却是错误确定性和分布崩解。因此，本文采用的是联合判断：有效校准应当同时满足 score 提升、低置信 token 减少、合理长度压缩、EOS 行为稳定和正确性分组优势，而不是只看某一个 token 指标。这个联合标准能避免把病态坍塌误读为“更自信”。

从这个角度看，full-data 的加入增强了正确性分组分析的说服力。Base 与 Instruct 的 full-data 设置都保留了正确组低熵、高 top-1 的方向性关系，说明该现象不局限于 one-shot 条件。尤其是 Instruct full-data，其错误组也相对更集中，表明高先验模型在 full-data 训练后不仅正确响应更稳定，错误响应的形态也更加收敛。这种现象为后续错误类型分析提供了线索：模型失败可能不再主要表现为漫游式低置信输出，而是表现为较稳定但答案路径错误的输出。

## 9.5 当前证据的整体边界

尽管证据链已经较完整，当前结论仍应保持适当边界。首先， $n=1$  与  $n=8$  的比较仍是单次训练结果，不能替代多 seed 稳健性评估。其次，full-data 虽然已纳入聚合 token diagnostics，但固定题目完整轨迹仍不是七组完全对称覆盖。再次，本文的验证集聚合指标可以支持行为校准解释，但还不能完全排除某些题型或难度区间上的知识获得。因此，最稳妥的结论应限定在当前实验范围内。

在这一范围内，七组实验共同支持如下机制图景：可验证奖励使模型更倾向于生成短而稳定、低熵且高置信的推理轨迹；这种变化在 Base 家族中表现为显著性能跃迁，在 Instruct 家族中表现为高起点附近的小幅 refinement；扩大数据预算可以进一步提高上限，但不会改变主要方向；削弱 group-relative signal 会降低收敛质量；破坏奖励结构则会使分布稳定化过程反向崩解。这个图景比单独报告 final score 更有解释力，也更接近论文层面的机制结论。

面向后续研究，最直接的扩展是把当前诊断从“设置层面对照”推进到“题目层面解释”。例如，可以按题目难度、知识点类型、初始模型是否已能答对、以及训练后是否发生正确性翻转，对验证集进行分层。若收益主要来自校准，那么改善应当较广泛地出现在原本接近可解但输出不稳定的题目上；若收益主要来自知识获得，则改善可能更集中于少数特定题型。当前实验尚未完成这种粒度的拆分，因此本文把“快速校准”作为最受当前证据支持的解释，而不是排他性的因果结论。

另一个值得补充的方向是多 seed 与多样本控制。当前  $n=1$  与  $n=8$  的同口径比较已经

足以说明 group size 会影响收敛质量, 但还不足以估计这种差距的方差。类似地, full-data 与 one-shot 的差距在 Base 和 Instruct 家族上都存在, 但其数值大小仍可能受到采样噪声、checkpoint 选择和训练批次顺序影响。因此, 若要把本文结论提升为更强的统计声明, 后续应优先补充多 seed 复验, 并报告每个设置在 best checkpoint 与 final checkpoint 上的均值和置信区间。

## 10 结论

本文围绕 1-shot GRPO 在数学推理任务中的作用机制，构建了一个由七组主结果设置、七组聚合行为诊断和更窄粒度 token 轨迹证据共同组成的证据框架。主结果表明，在 Qwen2.5-Math-1.5B 上，1-shot GRPO 可以带来接近 0.20 的显著分数提升，并伴随响应长度缩短、尾部置信度上升、token entropy 下降、低置信 token 减少以及结束行为更果断等一系列同步变化；而在 Qwen2.5-Math-1.5B-Instruct 上，训练效应则明显更接近高位微调。Matched full-data 对照进一步说明，Base 家族对数据预算扩展更为敏感，Instruct 家族的绝对收益整体更温和，同时 1-shot 结果虽有意义但仍低于同口径 full-data 结果。

综合主结果、动态指标、token 级补充证据与随机错误奖励设置，本文认为当前最稳妥的结论有三点。第一，1-shot GRPO 对 Base 数学推理模型是有效的。第二，这种收益更适合被解释为快速校准，而非知识注入；不过，完全分离二者仍需要按题目难度或知识领域分层的后续评估。第三，group-relative signal 与奖励结构都会影响最终收敛上限：将训练 group size 从 8 降到 1 会削弱但不会消除收益，而一旦奖励信号被系统性破坏，模型不仅不会复现正常奖励条件下的收益，反而会在分数与行为分布上同步崩解。当前仍需保留的边界在于， $n=1$  与  $n=8$  的同口径比较仍是单次训练结果，随机错误奖励设置也尚未扩展到 Instruct 家族。在这些边界内，现有证据已经支持将 1-shot GRPO 理解为一种主要作用于分布稳定化与行为校准的低数据强化学习机制。

## A 附录：补充讨论

**关于 Base 模型收益的补充说明** 在当前设置下，1-shot GRPO 对 Base 数学推理模型的作用主要体现为行为分布的稳定化，而非简单拉长推理链。模型在训练后显著缩短输出长度、降低 token entropy、减少低置信 token，并更果断地结束答案，这些现象共同支持“快速校准”解释。

**关于 Instruct 模型收益较小的补充说明** Instruct 模型在 step 0 已经具备较高的数学推理先验，因此 1-shot GRPO 的作用更接近局部微调与分布调整，而不是大幅纠偏。这也是其收益量级明显小于 Base 模型的主要原因。

**关于 n=1 结果的补充说明** n=1 小组规模消融结果说明，将 group size 降到 1 并不会阻止模型获得显著收益；但在与 n=8 相同的评估口径下，它仍然系统性落后于 n=8，因此当前证据更支持“group-relative signal 对最佳效果有帮助”这一判断。

**关于随机错误奖励设置的补充说明** Base 随机错误奖励设置直接采用错误奖励构造破坏性监督。结果显示，模型在该设置下不仅无法复现正常奖励条件下的收益，反而出现分数坍缩、熵爆炸、长度异常增长与停止行为失稳。这说明正文中的收益确实依赖于有意义的训练信号，而不是训练流程本身的偶然产物。

**关于旧版全量数据与格式约束参考的补充说明** 正文已经纳入 matched full-data 主结果。这里保留的是更早一批全量数据与格式约束参考结果，用于提供历史对照与补充背景，而不再承担正文主结论的主要证据角色。表 14 汇总了其中最具代表性的几条参考结果。整体上看，Base 家族中 full 训练明显强于 1-shot；Instruct 家族中也存在同方向差异，但绝对幅度更小。与此同时，一个格式约束主导参考仅从 0.3630 提升到 0.4490，明显弱于常规奖励路径，因此更适合作为正文外的辅助材料。

表 14: 全量数据与格式约束参考结果汇总

| 模型家族     | 设置                | 初始     | final  | best   |
|----------|-------------------|--------|--------|--------|
| Base     | 1-shot            | 0.3630 | 0.5753 | 0.5803 |
| Base     | full              | 0.3630 | 0.6053 | 0.6135 |
| Base     | 格式约束主导参考          | 0.3630 | 0.4490 | 0.4785 |
| Base     | 1-shot entropy 参考 | 0.3630 | 0.5698 | 0.5835 |
| Instruct | 1-shot            | 0.6860 | 0.6928 | 0.6985 |
| Instruct | full              | 0.6860 | 0.7070 | 0.7070 |
| Instruct | 1-shot 参考         | 0.6860 | 0.6893 | 0.7005 |
| Instruct | full 参考           | 0.6795 | 0.7118 | 0.7118 |

这些旧版结果更适合作为附录层面的参考材料，而不应与正文的 matched full-data 主结果混为一谈。更稳妥的写法是把它们作为“与主结论同向的补充证据”：一方面，full 普遍优于 1-shot；另一方面，格式约束较强的参考设置只能带来有限改善，这与正文中



“奖励结构和组内比较信号都会影响最终上限”的主线是一致的。附录因此只保留紧凑的数字参考，避免正文同时承载两套不同口径的 full-data 叙事。

## 参考文献

- [1] Wang, Y., Yang, Q., Zeng, Z., Ren, L., Liu, L., Peng, B., Cheng, H., He, X., Wang, K., Gao, J., Chen, W., Wang, S., Du, S. S., & Shen, Y. Reinforcement Learning for Reasoning in Large Language Models with One Training Example. arXiv preprint arXiv:2504.20571, 2025.
- [2] Luo, M., Tan, S., Wong, J., Shi, X., Tang, W. Y., Roongta, M., Cai, C., Luo, J., Li, L. E., Popa, R. A., & Stoica, I. DeepScaleR: Surpassing O1-Preview with a 1.5B Model by Scaling RL. Notion Blog, 2025.
- [3] DeepSeek-AI et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. arXiv preprint arXiv:2501.12948, 2025.
- [4] Kimi Team et al. Kimi k1.5: Scaling Reinforcement Learning with LLMs. arXiv preprint arXiv:2501.12599, 2025.
- [5] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. Proximal Policy Optimization Algorithms. arXiv preprint arXiv:1707.06347, 2017.
- [6] Shao, Z. et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. arXiv preprint arXiv:2402.03300, 2024.
- [7] Lightman, H., Kosaraju, V., Burda, Y., Edwards, H., Baker, B., Lee, T., Leike, J., Schulman, J., Sutskever, I., & Cobbe, K. Let’s Verify Step by Step. arXiv preprint arXiv:2305.20050, 2023.
- [8] Li, Y. et al. Competition-Level Code Generation with AlphaCode. arXiv preprint arXiv:2203.07814, 2022.
- [9] Rein, D., Hou, B. L., Stickland, A. C., Petty, J., Pang, R. Y., Dirani, J., Michael, J., & Bowman, S. R. GPQA: A Graduate-Level Google-Proof Q&A Benchmark. arXiv preprint arXiv:2311.12022, 2023.
- [10] Hendrycks, D. et al. Measuring Mathematical Problem Solving With the MATH Dataset. In Advances in Neural Information Processing Systems (NeurIPS), 2021; arXiv preprint arXiv:2103.03874.
- [11] Yang, A. et al. Qwen2.5-Math Technical Report: Toward Mathematical Expert Model via Self-Improvement. arXiv preprint arXiv:2409.12122, 2024.